

Các phương pháp có thể giải thích để phát hiện Trojan phần cứng: So sánh có hệ thống

Paul Whitten^{1*}, Francis Wolff^{1†} và Chris Papachristou^{1†}

¹Kỹ thuật Điện, Máy tính và Hệ thống, Đại học Case Western Reserve,
10900 Euclid Avenue, Cleveland, 44106, Ohio, Hoa Kỳ.

*(Các) tác giả tương ứng (Các) E-mail: pcw@case.edu;
Các tác giả đóng góp: fxw12@case.edu; cap2@case.edu;
†Các tác giả này đã đóng góp như nhau cho tác phẩm này.

Abstract

Trojan phần cứng là các mạch độc hại làm tổn hại đến chức năng và tính bảo mật của mạch tích hợp (IC). Các mạch này được sản xuất trực tiếp vào silicon và không thể sửa chữa bằng các bản vá bảo mật như phần mềm. Giải pháp sẽ yêu cầu thu hồi sản phẩm tồn kho bằng cách thay thế IC và do đó, việc phát hiện sớm trong quá trình thiết kế là điều cần thiết. Phát hiện phần cứng tốt nhất cung cấp các giải pháp dựa trên thống kê với nhiều kết quả dương tính giả và âm tính giả. Các phương pháp phát hiện này yêu cầu phân tích có thể giải thích kỹ lưỡng hơn để lọc ra các chỉ số sai.

Các phương pháp giải thích hiện tại được phát triển cho các lĩnh vực chung như phân loại hình ảnh không phải lúc nào cũng cung cấp những hiểu biết sâu sắc có thể hành động mà các kỹ sư phần cứng cần. Vẫn còn một câu hỏi: làm thế nào để phân tích thuộc tính nhận biết miền, lý luận dựa trên trường hợp mô hình bất khả tri và kỹ thuật phân bổ tính năng bất khả tri mô hình so sánh với các ứng dụng bảo mật phần cứng?

Công việc này so sánh ba loại khả năng giải thích để phát hiện trojan phần cứng cấp công trên tập dữ liệu điểm chuẩn Trust-Hub: (1) phân tích dựa trên thuộc tính nhận biết miền của 31 tính năng dành riêng cho mạch bắt nguồn từ các mẫu quạt cổng, khoảng cách flip-flop và kết nối Đầu vào/Đầu ra (I/O) chính; (2) lập luận dựa trên trường hợp bất khả tri bằng mô hình sử dụng k hàng xóm gần nhất để giải thích dựa trên tiền lệ; và (3) các phương pháp phân bổ tính năng bất khả tri của mô hình (Giải thích bất khả tri về mô hình có thể giải thích cục bộ (LIME), Giải thích phụ gia SHapley (SHAP), gradient) cung cấp điểm quan trọng chung mà không cần bối cảnh cấp mạch.

Các phát hiện cho thấy các phương pháp tiếp cận có thể giải thích khác nhau mang lại những lợi thế khác biệt cho những người thực hành bảo mật phần cứng. Phương pháp dựa trên thuộc tính nhận biết miền phân tích 31 thuộc tính mạch. Các quyết định phát hiện được giải thích thông qua

các khái niệm quen thuộc như “độ phức tạp của fanin cao ở gần đầu ra cho thấy các tác nhân kích hoạt trojan tiềm ẩn”. Lý luận dựa trên trường hợp (k-hàng xóm gần nhất) đạt được sự tương ứng 96,51% giữa các dự đoán và mẫu huấn luyện. Ngược lại, LIME và SHAP chỉ hiển thị thỏa thuận vừa phải trên mỗi cổng (Spearman $\rho = 0.30$ có nghĩa là trên $n = 11,392$ cổng, CI bootstrap 95% [0.29, 0.31]; nổi toàn cục $\rho = 0.31$, $p \ll 10^{-300}$) và mang lại điểm quan trọng về tính năng chung thiếu bối cảnh cấp mạch để xác thực hoặc lập kế hoạch khắc phục. Hiệu suất phát hiện bằng cách sử dụng phân loại eXtreme gradient Boosting (XGBoost) với ngưỡng được tối ưu hóa đạt được độ chính xác 48,08% và tỷ lệ thu hồi 69,44% trên 11.392 cổng kiểm tra được giữ lại ($F1 = 0,568$, Hệ số tương quan Matthews (MCC) = 0,575, diện tích bên dưới đường cong thu hồi chính xác (AUPRC) = 0,637) ở ngưỡng tối ưu hóa là 0,940. Điều này thể hiện sự cải thiện độ chính xác gấp 4,25 lần so với đường cơ sở của máy vectơ hỗ trợ (SVM) được triển khai lại trong các điều kiện thử nghiệm giống hệt nhau (độ chính xác 11,33%, tỷ lệ thu hồi 70,83%, $F1 = 0,195$ ở ngưỡng 0,050) với mật độ dương tính giả giảm 7,4 lần (4,74 so với 35,0 FP trên 1.000 cổng). Rừng ngẫu nhiên đạt được F1 tương đương (0,555, độ chính xác 58,46%, thu hồi 52,78%) với mật độ dương tính giả bằng một nửa của XGBoost (2,37 so với 4,74 FP trên 1.000 cổng), xác nhận rằng các phát hiện AI (XAI) có thể giải thích được khái quát hóa trên các lựa chọn phân loại.

Ngoài ra, phân bổ tính năng dựa trên độ dốc (Simonyan và cộng sự, 2013), với hệ số tăng tốc là 7 so với SHAP, mang lại trọng số tính năng bất khả tri theo mô hình tương tự như SHAP và LIME, xác nhận rằng chỉ riêng hiệu quả tính toán không thể thay thế cho khả năng diễn giải nhận biết miền.

Công việc này cung cấp bằng chứng thực nghiệm so sánh phân tích thuộc tính nhận biết miền, lý luận dựa trên trường hợp bất khả tri mô hình và kỹ thuật phân bổ tính năng bất khả tri mô hình cho các ứng dụng bảo mật phần cứng. Kết quả cho thấy các phương pháp tiếp cận dựa trên đặc tính và trường hợp mang lại những lợi ích bổ sung: sự liên kết miền và khả năng diễn giải dựa trên tiền lệ tương ứng so với xếp hạng đặc điểm chung. Những phát hiện này có ý nghĩa đối với việc triển khai XAI trên các lĩnh vực mà người thực hành phải xác thực và hành động theo các dự đoán của Học máy (ML).

Keywords: trí tuệ nhân tạo có thể giải thích, phát hiện trojan phần cứng, khả năng giải thích nhận biết miền, giải thích bất khả tri về mô hình, phân tích thuộc tính mạch, LIME, SHAP, XGBoost, điểm chuẩn Trust-Hub, Trình giải thích trường hợp

1 Introduction

Khi hệ thống máy học đánh dấu một cổng trong IC có hàng tỷ bóng bán dẫn là một trojan phần cứng tiềm ẩn, kỹ sư bảo mật cần được giải thích bằng thuật ngữ mạch điện. “Tầm quan trọng của tính năng: 0,73” không giúp ích gì nhiều cho việc xác thực hoặc khắc phục. Nếu không có những diễn giải dựa trên nguyên tắc thiết kế mạch, người thực hiện không thể tách cảnh báo thực khỏi cảnh báo giả, xác minh các mẫu cấu trúc đáng ngờ dựa trên kiến thức miền hoặc chuyển các phát hiện thành các hành động bảo mật.

Trojan phần cứng là các sửa đổi mạch độc hại được đưa vào trong quá trình thiết kế hoặc chế tạo. Không giống như lỗi phần mềm, chúng tồn tại vĩnh viễn trong silicon, được kích hoạt thông qua các kết hợp đầu vào hiếm được thiết kế để trốn tránh kiểm tra thông thường (thường là 1 trong 2^{64} trạng thái),

và hoạt động ở cấp cổng mà không có dấu vết phần mềm có thể nhìn thấy, có khả năng ảnh hưởng đến tính bảo mật, tính toàn vẹn hoặc tính khả dụng.

Các mô hình học máy gắn cờ các cấu trúc mạch đáng ngờ từ danh sách mạng cấp cổng, nhưng các dự đoán trong hộp mờ thiếu những lý do có thể giải thích được mà các kỹ sư bảo mật phần cứng cần có. Các kỹ thuật XAI có mục đích chung như LIME [1] và SHAP [2] giải thích các dự đoán thông qua nhiều loạn tính năng và phân bố lý thuyết trò chơi; chúng không liên quan đến miền và có thể áp dụng rộng rãi, nhưng tạo ra điểm số quan trọng chung. Ngược lại, các phương pháp nhận biết miền mã hóa kiến thức cụ thể về mạch (mẫu fanin, kết nối flip-flop, sự gắn gũi với I/O chính) trực tiếp vào phần giải thích, phù hợp với cách các kỹ sư phần cứng đã suy luận về mạch nhưng đòi hỏi nỗ lực thiết kế miền.

Do model-agnostic explainability techniques developed for general ML applications provide the actionable insights hardware security practitioners need, or do domain-aware methods tailored to circuit characteristics offer better interpretability?
Công việc trước đây chưa giải đáp được vấn đề này về mặt thực nghiệm.

Công việc này cung cấp sự so sánh thực nghiệm như vậy về điểm chuẩn Trust-Hub, đối chiếu phân tích thuộc tính mạch theo miền cụ thể với phân bố tính năng cho mục đích chung.

Những đóng góp chính là:

1.Domain-Aware Property Analysis: Phương pháp giải thích dựa trên thuộc tính nhằm phân tích 31 tính năng dành riêng cho mạch cấp cổng dựa trên nguyên tắc thiết kế phần cứng. Nó đưa ra những giải thích như “LGFi cao = 12 ở 2 cấp độ ngược dòng kết hợp với FFO thấp = 1 phù hợp với các mẫu kích hoạt sự kiện hiếm gặp”, mà các kỹ sư có thể xác thực bằng cách sử dụng các khái niệm phân tích mạch quen thuộc.

2.Case-Based Reasoning with k-Nearest Neighbors: Một công cụ dự đoán vốn có thể hiểu được ($k = 5$) đạt được sự tương ứng 96,51% giữa các dự đoán và mẫu huấn luyện, chứng minh việc phát hiện theo tiền lệ: “hồ sơ tính năng của cổng này khớp với 4 trong số 5 trường hợp huấn luyện tương tự là trojan”.

3.Systematic Quantitative Comparison with Model-Agnostic Baselines: M2–M5 sử dụng một bộ phân loại XGBoost duy nhất với năm phần phụ trợ giải thích hậu kiểm khác nhau, tách biệt tác động của cơ chế giải thích khỏi bộ phát hiện cơ bản. LIME và SHAP hiển thị thỏa thuận vừa phải trên mỗi cổng (Spearman $\rho = 0.30$ trên $n = 11,392$ cổng, CI bootstrap 95% [0.29, 0.31]; kết nối toàn cầu $\rho = 0.31$, $p \ll 10^{-300}$): tương quan đáng kể nhưng không giống nhau. Phân bố dựa trên độ dốc [3] cũng được đánh giá về hiệu quả tính toán.

4.Improved Detection Performance with XGBoost and Random Forest: XGBoost đạt độ chính xác 48,08% với tỷ lệ thu hồi 69,44% ($F1 = 0,568$, $MCC = 0,575$, $AUPRC = 0,637$); Rừng ngẫu nhiên đạt độ chính xác 58,46% với tỷ lệ thu hồi 52,78% ($F1 = 0,555$, $MCC = 0,553$, $AUPRC = 0,512$). Cả hai đều cải thiện đáng kể so với đường cơ sở Hasegawa SVM được triển khai lại trong các điều kiện giống nhau (độ chính xác 11,33%, thu hồi 70,83%, $F1 = 0,195$): độ chính xác $4,25\times$ (XGBoost) và mật độ dương tính giả thấp hơn $7,4\times$ (4,74 so với 35,0 FP trên 1.000 cổng).

Phần 2 đề cập đến trojan phần cứng và nền tảng XAI. Phần 3 đánh giá các công việc liên quan. Phần 4 và 5 trình bày phương pháp và bố trí thử nghiệm. Phần 6 báo cáo kết quả. Phần 7 thảo luận về những hạn chế và công việc trong tương lai. Phần 8 kết thúc.

2 Background

2.1 Hardware Trojans




Fig. 1: Phân loại mạch Trojan[4].

Gia công chế tạo mạch tích hợp dựa trên chi phí tạo ra cơ hội cho các trojan phần cứng làm suy yếu tính bảo mật, tính toàn vẹn hoặc tính khả dụng của các IC đáng tin cậy. Hình 1 cho thấy cách phân loại tiêu chuẩn: mỗi trojan bao gồm một trình kích hoạt và một tải trọng, mỗi trojan có thể là kỹ thuật số hoặc tương tự, với các giá trị hiếm, độ trễ k -bit hoặc các chuỗi đầu vào hiếm gặp làm điều kiện kích hoạt điển hình và thay đổi điều khiển/trạng thái/dữ liệu hoặc rò rỉ analog như các cách khai thác điển hình [4].




Fig. 2: Mô hình trojan phản ứng sự kiện hiếm có tính bảo mật[5].

Hình 2 cho thấy một trojan bảo mật được triển khai ở logic cấp cổng: một sự kiện VÀ kích hoạt hiếm gặp được điều chỉnh trên các cổng đầu vào chính một tải trọng của bộ ghép kênh làm rò rỉ dữ liệu nhạy cảm đến đầu ra chính. Khả năng phát hiện dựa trên việc hiếm khi kích hoạt trình kích hoạt (ví dụ: một trong 2^n kết hợp đầu vào) và tải trọng đạt đến đầu ra có thể quan sát được, do đó, phân tích cấp cổng tĩnh có thể gắn cờ các mạch con đáng ngờ theo độ phức tạp của quạt và khả năng tiếp cận các đầu ra chính [4, 6–8].

Hasegawa và cộng sự. [6, 7] mã hóa trực giác này thành năm tính năng trên mỗi mạng được sử dụng trong suốt tác phẩm này: Fanins cổng logic (LGF_i, đầu vào cho cổng logic hai cấp độ ngược dòng), Đầu vào Flip-Flop (FF_i, mức logic ngược dòng cho một flip-flop), Đầu ra Flip-Flop (FF_o, các mức logic xuôi dòng cho một flip-flop), Đầu vào chính (PI, các mức ngược dòng đến đầu vào chính gần nhất) và Đầu ra chính (PO, các mức logic xuôi dòng đến đầu ra chính gần nhất). SVM ban đầu của họ giải quyết sự mất cân bằng lớp thông qua trọng số động; công việc tiếp theo sử dụng lấy mẫu quá mức tổng hợp [9] và các chiến lược tái cân bằng khác nhưng không cải thiện khả năng diễn giải của các quyết định thu được.

2.2 Trust-Hub Benchmark Dataset

Điểm chuẩn Trust-Hub [8, 10–12] cung cấp cho danh sách mạng cấp cổng các phần chèn trojan được gắn nhãn. Công việc này sử dụng 30 mạch tổ hợp kỹ thuật số được rút ra từ các thiết bị ngoại vi truyền thông RS232 và điểm chuẩn ISCAS; các mạch cấp tương tự và bóng bán dẫn nằm ngoài phạm vi.

3 Related Work

3.1 Machine Learning for Hardware Trojan Detection

3.1.1 Hasegawa et al. Baseline

Hasegawa và cộng sự. đã thiết lập một phương pháp tiếp cận nền tảng để phát hiện trojan, phân cứng dựa trên ML từ danh sách mạng cấp cổng [6, 7]. Phương pháp của họ trích xuất năm đặc điểm cấu trúc từ mỗi mạng: LGF_i, FF_i, FF_o, PI và PO. Sử dụng Máy vectơ hỗ trợ (SVM)

phân loại bằng trọng số lớp động để giải quyết tình trạng mất cân bằng dữ liệu, họ đã báo cáo mức thu hồi 82,6% trên tập dữ liệu kiểm chuẩn Trust-Hub.

Độ chính xác được tính toán từ ma trận nhầm lẫn được công bố của họ là 5,13%. Khoảng 95% các cổng được gắn cờ trojan là dương tính giả. Ma trận nhầm lẫn được công bố của họ (Bảng V, trọng số động) cho thấy tỷ lệ âm tính thực trung bình là 49,5%, tương ứng với tỷ lệ dương tính giả khoảng 50,5%. Số lượng lớn các kết quả dương tính giả đã hạn chế tiện ích thiết thực cho việc triển khai trong thế giới thực, nơi các kỹ sư bảo mật phải kiểm tra thủ công các cổng bị gắn cờ sai.

Để cung cấp khả năng so sánh giữa các tác giả, công việc này thực hiện lại đường cơ sở Hasegawa SVM trong các điều kiện thử nghiệm giống hệt nhau: cùng một tập dữ liệu Trust-Hub, cùng năm tính năng cấu trúc và cùng mức phân chia ngẫu nhiên 60/20/20. Hạt nhân SVM (hàm cơ sở xuyên tâm (RBF) được triển khai lại, `class_weight='balanced'`) đạt được độ chính xác 11,33% và tỷ lệ thu hồi 70,83% ở ngưỡng giá trị tối ưu là 0,050 ($F1 = 0,195$, $MCC = 0,274$, 35,0 FP trên 1.000 cổng). XGBoost đạt độ chính xác 48,08% ở ngưỡng 0,940, cải thiện độ chính xác gấp 4,25 lần với mật độ dương tính giả giảm 7,4 lần (4,74 so với 35,0 FP trên 1.000 cổng). Rừng ngẫu nhiên tiếp tục giảm gánh nặng FP xuống 2,37 FP trên 1.000 cổng (gấp 14,8 lần so với đường cơ sở SVM) với độ chính xác 58,46%.

3.1.2 Recent Advances

Hệ thống HT-Pred của Rathor và Rastogi [13] sử dụng 479 mạch Trust-Hub với 605 tính năng cấu trúc và chức năng, lớn hơn đáng kể so với các bộ dữ liệu được xuất bản trước đó. Mạng lưới thần kinh sâu của họ đạt được độ chính xác 98,95% khi phân loại nhị phân cấp mạch (mạch có nhiễm trojan và không có trojan). Tuy nhiên, công việc của họ giải quyết một vấn đề cơ bản khác với công việc này: họ phân loại toàn bộ mạch thay vì bản địa hóa các cổng trojan cụ thể trong danh sách mạch. Phân loại cấp độ mạch được hưởng lợi từ các bộ dữ liệu cân bằng (tỷ lệ khoảng 1:1 giữa mạch bị nhiễm và mạch sạch) và cung cấp khả năng hành động hạn chế, vì các kỹ sư bảo mật vẫn phải tìm kiếm thủ công qua hàng trăm hoặc hàng nghìn cổng để xác định vị trí các thành phần trojan thực tế.

Ngược lại, công việc này thực hiện việc bản địa hóa trojan cấp cổng (cấp nút) trên các tập dữ liệu mất cân bằng nặng (khoảng 158 trên một tỷ lệ lành tính với cổng trojan), xác định trực tiếp các cổng đáng ngờ để cho phép khắc phục có mục tiêu. Trong khi HT-Pred đạt được độ chính xác tổng thể cao hơn ở tác vụ cấp mạch, bản địa hóa cấp cổng cung cấp thông tin cụ thể cần thiết để loại bỏ hoặc giảm thiểu trojan thực tế.

3.1.3 Ensemble Methods for Hardware Trojan Detection

Negishi và Togawa [9] so sánh Rừng ngẫu nhiên, AdaBoost và Tăng cường độ dốc với SVM trên Trust-Hub, nhận thấy các phương pháp tổng hợp luôn cải thiện thước đo F trong nhiệm vụ phát hiện mất cân bằng. Phương pháp 1 trong công việc này sử dụng một tập hợp gồm 31 bộ phân loại XGBoost, mỗi bộ phân loại được huấn luyện trên một tập con riêng biệt của 5 tính năng Hasegawa thay vì trên dữ liệu được lấy mẫu lại, được tổng hợp bằng biểu quyết có trọng số E_{PARS} . Cấu trúc tập hợp con mang lại khả năng diễn giải ở cấp thuộc tính mà các tập hợp đồng nhất (Random Forest, AdaBoost) không cung cấp.

3.1.4 Class Imbalance Handling in Hardware Trojan Detection

Danh sách mạng cấp công Trust-Hub có tỷ lệ tổng thể lành tính với trojan là 158:1 và 157:1 trong lần thử nghiệm được tổ chức. Các bộ phân loại được đào tạo mà không xử lý sự mất cân bằng thiên về lớp đa số. Các phản hồi tiêu chuẩn bao gồm tính lại trọng số [14], lấy mẫu quá mức tổng hợp và học tập nhảy cảm với chi phí. Tác phẩm này sử dụng $scale_pos_weight$ của XGBoost được đặt thành N_{benign}/N_{trojan} , tuân theo quy định về trọng số của King và Zeng [14] và đạt được tỷ lệ thu hồi 69,44% trong lần thử nghiệm 157:1.

Bảng 1 so sánh công việc hiện tại với các phương pháp phát hiện trojan cấp công đại diện trước đó trên điểm chuẩn Trust-Hub. Các hàng có cùng giao thức sử dụng các phân tách và ngưỡng giống hệt nhau; các hàng đã xuất bản được đưa vào ngữ cảnh và không thể so sánh trực tiếp.

Các hàng có cùng giao thức thiết lập sự so sánh về mức độ quan tâm: trong các phân phân tách, ngưỡng và số liệu giống hệt nhau, trình phát hiện tăng cường độ dốc cải thiện đáng kể độ chính xác so với đường cơ sở Hasegawa SVM (48,08% so với 11,33%, cải thiện gấp 4,25 lần) ở mức thu hồi tương đương. Các trình phát hiện dựa trên đồ thị hoạt động trên các đặc điểm cục bộ phong phú hơn và không thể so sánh trực tiếp trên biểu diễn năm đặc điểm này. Những con số được công bố của họ được đưa vào để xác định dòng công việc hơn là để khẳng định sự ngang bằng.

3.2 Explainable AI Techniques

3.2.1 General XAI Methods

Các phương pháp quan trọng của tính năng xác định tính năng đầu vào nào thúc đẩy dự đoán, trên toàn cầu hoặc cục bộ; các phương pháp dựa trên ví dụ như lý luận dựa trên trường hợp [17] lấy các trường hợp đào tạo tương tự làm lời giải thích; các phương pháp phân bổ (LIME [1], SHAP [2]) chỉ định điểm quan trọng cho mỗi tính năng, với SHAP cung cấp đảm bảo tính nhất quán và độ chính xác cục bộ với chi phí điện toán cao hơn.

3.2.2 XAI for Hardware Security

AI có thể giải thích được áp dụng để phát hiện trojan cấp công vẫn còn ít. Một tìm kiếm có hệ thống trên các ấn phẩm 2016–2025 (các truy vấn: “trojan phản ứng AI có thể giải thích được”, “bảo mật phản ứng máy học có thể giải thích được”, “phát hiện trojan phản ứng XAI”, “phân tích danh sách mạng ở cấp độ công có thể giải thích”) cho thấy không có công việc nào trước đó so sánh một cách có hệ thống nhận thức miền với các phương pháp XAI không xác định mô hình trên điểm chuẩn Trust-Hub. Hầu hết việc phát hiện trojan dựa trên ML đều sử dụng các mô hình hộp mờ mà không có khả năng giải thích [6, 7, 9, 13]; khi các giải thích xuất hiện, chúng thường là bảng xếp hạng tầm quan trọng của tính năng Rừng ngẫu nhiên mà không có đánh giá theo nhiều phương pháp.

Các công trình XAI có liên quan trực tiếp nhất: Pan và Mishra [18] áp dụng SHAP và LIME để phát hiện phần mềm độc hại phản ứng thông qua các tính năng đếm hiệu suất, một không gian tính năng khác nhưng có cùng động lực kiểm tra XAI. Mahfuz và cộng sự. (SALTY) [15] kết hợp một mạng lưới thần kinh đồ thị với tính chính XAI hậu học và báo cáo $TPR = 98,47\%$, $TNR = 98,14\%$ trên bộ tính năng cục bộ 125 chiều theo xác thực chéo loại bỏ một họ, minh họa khoảng trống có sẵn từ các biểu diễn phong phú hơn. Yasaei và cộng sự. [16] cho thấy rằng các biểu diễn tính năng GNN cải thiện khả năng khái quát hóa xuyên mạch trên đường cơ sở Hasegawa năm tính năng. Ma và cộng sự. [19] mở rộng khả năng phát hiện dựa trên GNN

với tính trung tâm hài hòa trên Trust-Hub. Su và cộng sự. [20] đề xuất một GNN có thể giải thích được cho việc bản địa hóa trojan cấp độ LUT trong danh sách mạng FPGA. Không có phương pháp nào trong số này so sánh một cách có hệ thống các phương pháp XAI trên biểu diễn tính năng cấu trúc cấp công cụ định.

Công việc này lấp đầy khoảng trống đó bằng cách so sánh năm phương pháp có thể giải thích bao gồm phân tích thuộc tính nhận biết miền, lý luận dựa trên trường hợp mô hình bất khả tri và phân bổ tính năng bất khả tri mô hình (LIME, SHAP, gradient) về hiệu suất phân loại, tính nhất quán giải thích và hiệu quả tính toán.

3.3 Explainable Artificial Intelligence




Fig. 3: Tương tác AI truyền thống tương phản với XAI[21].

Hình 3 minh họa mục tiêu của trí tuệ nhân tạo có thể giải thích được. Các tương tác ML hiện tại được mô tả ở trên cùng dưới dạng AI truyền thống. Vì ML hoạt động như một chiếc hộp mờ đục nên người dùng sẽ đặt câu hỏi về quyết định do AI đưa ra. Mục đích là cung cấp cho người dùng một mô hình và giao diện có thể giải thích được. Hệ thống kết quả, được hiển thị ở cuối hình, có thể đưa ra lời giải thích cùng với quyết định hoặc khuyến nghị. Để cải thiện niềm tin, những lời giải thích cần cung cấp sự hiểu biết về lý do tổng thể và các lựa chọn thay thế của hệ thống. Mục tiêu của XAI là trả lời những câu hỏi quan trọng được mô tả trong Hình 3 cho người dùng[21].

Việc ánh xạ một bộ phân loại học tập theo những lời giải thích mà con người có thể hiểu được vẫn còn là một thách thức. Các kỹ thuật được khảo sát bao gồm cây quyết định, dựa trên quy tắc, lập bản đồ độ nổi bật, Grad-CAM, phân tích độ nhạy, tầm quan trọng của đặc điểm, thần kinh mờ và lập trình di truyền và được đánh giá thông thường theo một trong ba mô hình: dựa trên ứng dụng, dựa trên con người và dựa trên chức năng [22–30].

Mô hình Mạng thần kinh có thể giải thích (NN) được đề xuất bởi Vaughan et al. bao gồm các lớp NN riêng biệt được huấn luyện dựa trên các phép biến đổi của đầu vào. Sau đó, một lớp kết hợp đầu ra của các NN riêng biệt để thực hiện dự đoán. Khả năng giải thích đến từ mỗi khía cạnh tách biệt của mô hình NN riêng biệt của đầu vào, điều này mang lại khả năng diễn giải của kiến trúc [31].

Giải thích dựa trên trường hợp cho các mô hình y tế, được giới thiệu bởi Caruana và cộng sự, đã đề xuất sử dụng phương pháp dựa trên khoảng cách k-lân cận gần nhất (k-NN) trong không gian đặc trưng đa chiều để có hiệu quả trong việc xác định các trường hợp tương tự từ quá trình đào tạo để giải thích cho các mẫu mới [17]. Các trường hợp từ quá trình đào tạo sẽ tạo ra kết quả tương tự như các mẫu mới nếu chúng giống nhau. Phương pháp dựa trên trường hợp cho thấy rằng việc sử dụng dữ liệu huấn luyện sẽ khó khăn hơn đối với các mô hình phức tạp như NN vì tập huấn luyện bị loại bỏ. Trong trường hợp NN, việc kích hoạt tế bào thần kinh ẩn n được chuyển thành các điểm trong không gian chiều n và thuật toán k-NN có thể được áp dụng để tìm các mẫu kích hoạt tương tự. Mặc dù điều này có thể gợi ý sự tương đồng với hoạt động và hành vi của NN giữa các trường hợp giống nhau, nhưng phương pháp này không thể giải thích được điều gì đang xảy ra trong NN.

Công việc trước đây về LIME giải thích các mẫu riêng lẻ bằng cách làm xáo trộn mẫu cục bộ và lắp một chất thay thế có thể giải thích được [1]. Đối với dữ liệu dạng bảng, mỗi tính năng bị nhiễu loạn một cách độc lập bằng cách lấy mẫu từ phân phối huấn luyện và các trọng số tầm quan trọng của tính năng thu được sẽ định lượng sự đóng góp của từng tính năng cho quyết định cục bộ.

SHAP cũng cung cấp các giải thích định lượng cho các dự đoán bằng cách gán cho mỗi đặc điểm một giá trị quan trọng dựa trên các giá trị Shapley theo lý thuyết trò chơi[2]. Các giá trị SHAP tổng hợp sự khác biệt giữa dự đoán của mô hình và dự đoán cơ sở (trung bình), cung cấp lời giải thích bổ sung hoàn chỉnh với độ chính xác cục bộ chính thức và đảm bảo tính nhất quán rằng phép tính gần đúng tuyến tính cục bộ của LIME không đáp ứng. Phần 6 báo cáo giá trị SHAP trên các công kiểm tra thực tế.

Mặc dù một số phương pháp có thể giải thích được thảo luận cung cấp điểm quan trọng về tính năng định lượng cho các dự đoán, nhưng các phương pháp hiện có đã biết không cung cấp lời giải thích đầy đủ bằng văn bản cho người dùng.

4 Methodology

Phần này mô tả phương pháp phát hiện trojan phần cứng ở cấp độ cổng bằng AI có thể giải thích được. Việc trích xuất tính năng từ danh sách mạng Verilog được trình bày trước tiên, sau đó là mô tả về bộ phân loại phát hiện dựa trên XGBoost và cuối cùng là chi tiết về năm phương pháp giải thích được đánh giá. Việc đánh giá bao gồm hai loại cấp cao nhất: một phương pháp nhận biết miền (Dựa trên thuộc tính, M1) và bốn phương pháp bất khả tri mô hình (M2–M5). Trong danh mục bất khả tri về mô hình, hai danh mục phụ được phân biệt: một phương pháp dựa trên tiền lệ vốn có thể hiểu được thông qua quyền ưu tiên từ dữ liệu huấn luyện (K-NN dựa trên trường hợp, M2) và ba phương pháp toán học, còn được gọi là phương pháp phân bổ tính năng trong tài liệu XAI (LIME, SHAP và Phân bổ độ dốc, M3–M5). Hình 4 minh họa hệ thống phân cấp này; Bảng 2 trình bày chi tiết cơ sở lý thuyết và trực chính của từng phương pháp.

4.1 Feature Extraction from Gate-Level Netlists

Việc phát hiện trojan phần cứng yêu cầu chuyển đổi danh sách mạng Verilog cấp cổng thành các đặc điểm số phù hợp cho việc phân loại máy học. Như được mô tả trong Phần 2, trojan phần cứng thường bao gồm hai thành phần: *rare-event triggers* yêu cầu nhiều điều kiện đầu vào cụ thể để kích hoạt và *payloads* truyền tín hiệu độc hại đến các đầu ra có thể quan sát được. Những đặc điểm kiến trúc này thúc đẩy việc lựa chọn tính năng tập trung vào việc đo lường độ phức tạp của kích hoạt và sự lan truyền tải trọng.




Fig. 4: Phân loại theo thứ bậc của năm phương pháp giải thích được đánh giá trong tác phẩm này. Hai loại cấp cao nhất phân chia không gian thiết kế: *domain-aware* phương pháp kết hợp kiến thức cụ thể về mạch (M1) và *model-agnostic* phương pháp giải thích các phân loại tùy ý hậu kỳ mà không kiểm tra nội bộ mô hình (M2–M5). Các phương pháp bất khả tri về mô hình chia thành hai loại phụ: các phương pháp *precedent-driven* vốn có thể diễn giải được thông qua mức độ ưu tiên từ dữ liệu huấn luyện (M2) và các phương pháp *mathematical* (còn được gọi là các phương pháp phân bổ tính năng trong tài liệu XAI [1–3]) gán điểm số cho các tính năng đầu vào thông qua các dẫn xuất toán học hình thức (M3–M5).

Theo dõi Hasegawa et al. [6, 7], năm đặc điểm cấu trúc được trích xuất cho mỗi cổng (mạch) trong mạch nắm bắt các đặc điểm liên quan đến trojan này. Tính năng đầu tiên đo lường độ phức tạp của kích hoạt, hai tính năng tiếp theo đo mức độ gần với các phân tử trạng thái và hai tính năng cuối cùng nắm bắt kết nối đầu vào và đầu ra chính có liên quan để kích hoạt kích hoạt và truyền tải trọng tải.

Năm tính năng cơ bản là: (1)**LGFi**: số lượng đầu vào vào cổng logic hai cấp độ ngược dòng từ một cổng, nắm bắt độ phức tạp đầu vào có thể chỉ ra các mạch kích hoạt yêu cầu kết hợp đầu vào hiếm (bộ kích hoạt có n đầu vào yêu cầu một kết hợp cụ thể từ 2^n khả năng); (2)**FFi**: số mức logic ngược dòng tới flip-flop gần nhất, đo độ gần với các phân tử trạng thái; (3)**FFo**: số mức logic xuôi dòng tới flip-flop gần nhất, biểu thị đường truyền tín hiệu; (4)**PI**: số mức logic ngược dòng tới đầu vào chính gần nhất; (5)**PO**: số mức logic xuôi dòng đến đầu ra chính gần nhất, liên quan đến việc truyền tải trọng đến các vị trí có thể quan sát được nơi kẻ tấn công có thể trích xuất dữ liệu nhạy cảm.

Công việc này áp dụng cách tiếp cận năm đặc điểm của Hasegawa và cộng sự thay vì bộ 605 đặc điểm mở rộng được Rathor và Rastogi [13] sử dụng vì hai lý do. Đầu tiên, các tính năng của Hasegawa tạo thành cơ sở thiết lập cho việc bản địa hóa trojan cấp cổng, cho phép so sánh hiệu suất trực tiếp. Thứ hai, trọng tâm chính của công việc này là so sánh khả năng giải thích thay vì hiệu suất phát hiện tối đa thông qua kỹ thuật tính năng năm

các tính năng cung cấp các đặc tính mạch có thể hiểu được (độ phức tạp của fanin, khả năng kết nối flip-flop, độ gần I/O) mà các kỹ sư phân cứng dễ dàng hiểu và có thể hành động theo.

Các tính năng này được trích xuất bằng CircuitGraph [32], một thư viện Python để phân tích danh sách mạng cấp cổng. Danh sách mạng Verilog được phân tích cú pháp bằng bộ công cụ phân tích cú pháp Lark [33] và biểu diễn đồ thị có hướng được xây dựng bằng NetworkX [34]. Đối với mỗi cổng trong mạch, tất cả năm tính năng đều được tính toán thông qua thuật toán truyền tải đồ thị, gắn nhãn cổng là trojan (1) hoặc lành tính (0) dựa trên chú thích sự thật cơ bản của Trust-Hub.

4.2 XGBoost Classifier for Trojan Detection

XGBoost [35] được sử dụng làm bộ phân loại nhị phân để phát hiện trojan cấp cổng. XGBoost được chọn vì hiệu suất của nó trên dữ liệu dạng bảng không cân bằng, xử lý hiệu quả sự mất cân bằng lớp thông qua các cơ chế tính trọng số tích hợp và khả năng cung cấp điểm quan trọng của tính năng cho các phương pháp giải thích bất khả tri về mô hình.

Thách thức chính trong việc phát hiện trojan ở cấp độ cổng là sự mất cân bằng cực độ giữa các lớp. Trong tập dữ liệu điểm chuẩn Trust-Hub, tỷ lệ cổng lành tính so với cổng trojan là khoảng 157 trên một (11.320 cổng lành tính so với 72 cổng trojan trong dữ liệu thử nghiệm). Phân loại tiêu chuẩn mà không có sự cân bằng lớp sẽ dẫn đến một bộ phân loại tầm thường gắn nhãn tất cả các cổng là lành tính, đạt được độ chính xác 99,3% nhưng thu hồi 0% đối với trojan.

Để giải quyết sự mất cân bằng lớp, tham số `scale_pos_weight` của XGBoost được sử dụng, chỉ định mức phạt tổn thất cao hơn đối với việc phân loại sai các mẫu lớp thiểu số (trojan). Tham số được đặt thành $\text{scale_pos_weight} = \frac{N_{benign}}{N_{trojan}}$ tỷ lệ mất cân bằng của N_{benign} và N_{trojan} lần lượt là số lượng mẫu huấn luyện lành tính và trojan. Sơ đồ tính trọng số này tuân theo cách tiếp cận của King và Zeng [14] đối với dữ liệu các sự kiện hiếm, khuyến khích mô hình tìm hiểu các mẫu trojan bất chấp độ hiếm của chúng.

Mô hình XGBoost sử dụng các siêu tham số sau: 100 công cụ ước tính (cây quyết định), độ sâu tối đa là 6 để ngăn chặn việc trang bị quá mức trên các mẫu trojan thừa thớt, tốc độ học là 0,3 và `objective='binary:logistic'` để phân loại nhị phân với đầu ra xác suất. Quá trình đào tạo được thực hiện trên 60% tập dữ liệu điểm chuẩn Trust-Hub kết hợp (34.175 mẫu) với lựa chọn ngưỡng trên bộ xác thực 20% được giữ lại (11.392 mẫu) và đánh giá cuối cùng trên một bộ kiểm tra 20% riêng biệt (11.392 mẫu), duy trì sự mất cân bằng lớp tự nhiên trong cả hai phần tách để phản ánh các kịch bản triển khai trong thế giới thực.

4.3 Explainability Methods

Các phương pháp có thể giải thích từ ba loại được đánh giá: phương pháp nhận biết miền kết hợp kiến thức cụ thể về mạch, các mô hình có thể hiểu được vốn có cơ chế dự đoán minh bạch theo thiết kế và các phương pháp bất khả tri về mô hình giải thích các mô hình ML tùy ý thông qua phân tích hậu kiểm.

4.3.1 Domain-Aware: Property-Based Circuit Analysis

Phương pháp Dựa trên Thuộc tính phân tích các mẫu tính năng dành riêng cho mạch bắt nguồn từ năm tính năng cơ bản (LGF_i, FF_i, FFO, PI, PO). Thay vì giải thích những dự đoán

thông qua trọng số của mỗi tính năng, phương pháp này xác định các tổ hợp thuộc tính mạch mà các kỹ sư phân cứng nhận ra là dấu hiệu trojan tiềm ẩn.

31 thuộc tính phái sinh được xây dựng từ năm tính năng cơ bản: năm thuộc tính tính năng đơn (ví dụ: “LGF_i cao biểu thị fanin phức tạp”), mười kết hợp hai tính năng (ví dụ: “LGF_i cao kết hợp với khoảng cách PO thấp biểu thị trình kích hoạt gần đầu ra”), mười kết hợp ba tính năng, năm kết hợp bốn tính năng và một kết hợp năm tính năng. Mỗi thuộc tính đại diện cho một mẫu mạch có thể nhận biết được với các hàm ý bảo mật dựa trên nguyên tắc thiết kế trojan phân cứng [4].

Lựa chọn năm tính năng là một quyết định thử nghiệm có kiểm soát: việc giữ lại chính xác bộ tính năng Hasegawa cho phép so sánh trực tiếp giữa các tảo với đường cơ sở SVM trước đó [6]. Nền tảng bảo mật của từng tính năng được tóm tắt trong Bảng 3, theo phân loại trojan của Wang và cộng sự. [4]. 31 bộ phân loại bao gồm tất cả các tập hợp con không trống của năm đặc điểm này. Mỗi bộ phân loại đa tính năng sẽ phát hiện các công kết hợp các đặc điểm riêng lẻ trong Bảng 3. Do đó, các thuộc tính của M1 dựa trên sự kết hợp tính năng: nhận thức miền được thực hiện ở cấp đầu ra giải thích, trong đó các quyết định được thể hiện thông qua nhãn khái niệm bảo mật phân cứng (Bảng 3), thay vì thông qua các tiên đề miền dẫn xuất độc lập. Bởi vì M1 chỉ hoạt động dựa trên năm đặc điểm cấu trúc của Hasegawa và không kết hợp các đặc tính chức năng, thời gian hoặc sức mạnh nên nó không trải rộng trên toàn bộ phạm vi phân tích danh sách mạng cấp công. Trong không gian tính năng bị ràng buộc này, M1 được mô tả chính xác hơn là miền-*aligned*: các giải thích của nó dựa trên từ vựng bảo mật phân cứng, nhưng cách trình bày cơ bản bị giới hạn ở các tính năng lân cận về cấu trúc thay vì miền hoàn chỉnh.

Đối với mỗi thuộc tính, một bộ phân loại nhị phân XGBoost riêng biệt được huấn luyện với trọng số lớp (tham số `scale_pos_weight`). 31 mô hình XGBoost tạo thành một tập hợp trong đó mỗi thành viên bỏ phiếu xem công đầu vào có phải là trojan hay không dựa trên mẫu thuộc tính cụ thể của nó. Các phiếu bầu được tổng hợp bằng cách sử dụng biểu quyết có trọng số, trong đó phiếu bầu của mỗi bộ phân loại được đánh giá bằng số liệu hiệu quả của mỗi lớp E_{PARS} (Hiệu quả là sản phẩm của Độ chính xác, Độ chính xác, Khả năng thu hồi và Tính đặc hiệu [36]), có khả năng phục hồi trước sự mất cân bằng giữa các lớp.

Với một công đầu vào có các tính năng $(f_1, f_2, f_3, f_4, f_5)$, mỗi bộ phân loại trong số 31 bộ phân loại tạo ra một dự đoán nhị phân $p_j \in \{0, 1\}$ và hệ thống tính toán độ tin cậy có trọng số cho mỗi lớp bằng cách sử dụng các trọng số hiệu quả được lưu trữ trong quá trình đào tạo. Dự đoán cuối cùng chọn lớp có độ tin cậy cao nhất. Giải thích xác định mẫu thuộc tính nào được bầu chọn cho lớp được dự đoán. Các kỹ sư hiểu được các quyết định thông qua các khái niệm mạch quen thuộc như “độ phức tạp của fanin cao (LGF_i=12) ở 2 cấp độ kết hợp với mức độ gần với đầu ra chính (PO=1) khớp với các dấu hiệu kích hoạt sự kiện hiếm gặp”.

4.3.2 Inherently Interpretable: Case-Based Reasoning with k-Nearest Neighbors

Phương pháp dựa trên trường hợp thể hiện một cách tiếp cận dự đoán vốn có thể giải thích được trong đó cơ chế phân loại tự cung cấp các giải thích tự nhiên thông qua việc huấn luyện sự tương ứng mẫu mực. Phương pháp này giải thích các dự đoán bằng cách xác định các ví dụ đào tạo tương tự, theo phương pháp chẩn đoán y tế của Caruana et al. [17]. Thay vì kết hợp kiến thức về mạch theo miền cụ thể, phương pháp này cung cấp

Table 3: Ngữ nghĩa bảo mật của năm đặc điểm cấu trúc Hasegawa được sử dụng trong Phương pháp 1. Các diễn giải dựa trên Wang et al. phân loại trojan phân cứng [4] và Hasegawa et al. định nghĩa đặc trưng [6]. Giá trị cao/thấp tương đối với dân số mạch. Hướng bất thường đặc trưng cho các cổng giống trojan đã được ghi nhận.

Feature	Definition	Security semantic
LGF _i	Logic-gate fanin depth (combinational cone depth)	Abnormally high: deep logic cone typical of trigger circuits that must count rare events through cascaded gates
FF _i	Flip-flop input distance (cycles from last register output)	Abnormally high: long sequential path from last register, consistent with rarely-activated trigger logic
FF _o	Flip-flop output distance (cycles to next register input)	Abnormally low: gate whose output feeds quickly into a register, consistent with payload delivery circuitry
PI	Primary input distance (combinational hops from a PI)	Abnormally high: gate not driven directly from any primary input, consistent with internal trigger logic
PO	Primary output distance (combinational hops to a PO)	Abnormally low: gate close to an observable output, consistent with payload or trigger-observation points

giải thích trực quan về dạng “cổng này được phân loại là trojan vì nó gần giống với các cổng trojan X, Y, Z đã biết từ dữ liệu huấn luyện”.

Khả năng giải thích dựa trên trường hợp được triển khai bằng cách sử dụng gói trình giải thích trường hợp [37], một thư viện có mục đích chung để giải thích dựa trên trường hợp bất khả tri mô hình với k-NN. Phương thức này sử dụng $k = 5$ lân cận trong không gian đặc trưng năm chiều. Đối với mỗi cổng kiểm tra, khoảng cách Euclide đến tất cả các mẫu huấn luyện được tính toán và 5 lân cận gần nhất với nhãn lớp và giá trị đặc trưng của chúng được truy xuất. Dự đoán được đưa ra bằng đa số phiếu bầu giữa k lớp hàng xóm.

Để định lượng chất lượng giải thích, **correspondence metric** tính toán sự phù hợp giữa các dự đoán và các hàng xóm được truy xuất bằng cách sử dụng biểu quyết theo trọng số khoảng cách. Thay vì bỏ phiếu theo đa số đơn giản, thư từ sẽ gán trọng số lớn hơn cho những người hàng xóm gần gũi hơn thông qua việc tính trọng số khoảng cách bình phương nghịch đảo:

$$w(c) = \sum_{i=1}^{|c|} \frac{1}{(d_i + 1.0)^2} \quad (1)$$

trong đó $w(c)$ là trọng số của lớp c và d_i là khoảng cách Euclide đến lớp lân cận i . Số liệu tương ứng cho lớp được dự đoán khi đó là:

$$C(c) = \frac{w(c)}{\sum_{j=1}^{classes} w(j)} \quad (2)$$

Ví dụ: nếu một cổng được dự đoán là trojan với 4 trojan lân cận ở khoảng cách [0,0, 1,0, 1,0, 2,0] và 1 lân cận lành tính ở khoảng cách 2,0 thì mức tương ứng là 94.2%. Mức độ tương ứng cao (gần 100%) cho thấy rằng dự đoán được hỗ trợ mạnh mẽ bởi các ví dụ đào tạo tương tự, mang lại sự biện minh đáng tin cậy. Tỷ lệ tương ứng thấp (dưới 70%) báo hiệu sự mơ hồ hoặc khả năng phân loại sai cần phải xem xét thủ công.

Phương pháp Case-Based bảo toàn nguồn gốc hoàn chỉnh cho từng hàng xóm được truy xuất, bao gồm tên mạch gốc, phiên bản, số dòng và tên mạng. Điều này cho phép các kỹ sư kiểm tra các ví dụ đào tạo thực tế trong bối cảnh danh sách mạng ban đầu của họ, xác minh xem liệu những điểm tương đồng về cấu trúc có phù hợp với kiến thức miền về đặc điểm trojan hay không.

Trên toàn bộ tập kiểm tra, phương pháp Dựa trên trường hợp đạt được mức độ tương ứng trung bình 96,51% giữa các dự đoán và các lớp lân cận gần nhất. Dự đoán rất phù hợp với các ví dụ được truy xuất. Sự tương ứng mạnh mẽ này xác nhận rằng bộ phân loại k-NN tìm hiểu các mẫu có ý nghĩa trong không gian đặc trưng và cung cấp các biện minh dựa trên trường hợp đáng tin cậy dựa trên tiền lệ.

4.4 Model-Agnostic Explainability Methods

Các phương pháp giải thích bất khả tri về mô hình cung cấp điểm quan trọng của tính năng mà không kết hợp kiến thức về miền, coi mô hình ML như một hộp mờ. Những phương pháp này được phát triển cho các ứng dụng học máy nói chung và cung cấp khả năng ứng dụng phổ biến trên các mô hình và lĩnh vực khác nhau. Ba kỹ thuật bất khả tri về mô hình được đánh giá để so sánh với phương pháp nhận biết miền.

4.4.1 LIME: Local Interpretable Model-Agnostic Explanations

LIME (Giải thích bất khả tri về mô hình có thể giải thích cục bộ) [1] giải thích các dự đoán riêng lẻ bằng cách điều chỉnh các mô hình tuyến tính cục bộ có thể giải thích được xung quanh điểm dự đoán. LIME làm xáo trộn các tính năng đầu vào và quan sát cách dự đoán thay đổi để xác định tính năng nào ảnh hưởng nhiều nhất đến quyết định cụ thể.

Đối với mỗi cổng kiểm tra, LIME tạo ra 1.000 mẫu nhiễu loạn bằng cách thay đổi ngẫu nhiên từng đặc điểm trong số năm đặc điểm trong phạm vi quan sát được của chúng trong dữ liệu huấn luyện. Mỗi mẫu nhiễu loạn được phân loại theo mô hình XGBoost đã huấn luyện và LIME phù hợp với mô hình hồi quy tuyến tính có trọng số trong đó trọng số giảm dần theo cấp số nhân theo khoảng cách từ mẫu ban đầu. Các hệ số mô hình tuyến tính thu được biểu thị điểm quan trọng của tính năng: hệ số dương biểu thị các tính năng làm tăng xác suất trojan, trong khi hệ số âm biểu thị các tính năng làm giảm xác suất đó.

LIME đưa ra các giải thích cục bộ cụ thể cho từng cổng riêng lẻ. Lời giải thích LIME điển hình xác định các tính năng như “FFo có tầm quan trọng +0,0526” hoặc “LGF_i có tầm quan trọng -0,0342,” cho biết mức độ đóng góp của mỗi tính năng đối với trojan/lành tính

phân loại cho công cụ thể đó. Tuy nhiên, những điểm quan trọng này thiếu bối cảnh ở cấp độ mạch: các kỹ sư phải giải thích “tầm quan trọng của FFO +0,0526” nghĩa là gì đối với bảo mật phần cứng mà không có mối liên hệ rõ ràng với các nguyên tắc thiết kế mạch.

4.4.2 SHAP: Shapley Additive Explanations

SHAP (Giải thích bổ sung SHapley) [2] tính toán tầm quan trọng của đặc điểm bằng cách sử dụng các giá trị Shapley từ lý thuyết trò chơi hợp tác. SHAP chỉ định cho mỗi tính năng một điểm phân bổ thể hiện sự đóng góp của nó trong việc chuyển dự đoán từ đường cơ sở (đầu ra mô hình dự kiến) sang dự đoán thực tế cho một mẫu cụ thể. Không giống như phép tính gần đúng tuyến tính cục bộ của LIME, SHAP cung cấp các phân bổ tính năng có cơ sở về mặt lý thuyết với sự đảm bảo chính thức về tính nhất quán và độ chính xác cục bộ.

SHAP được triển khai bằng thuật toán TreeExplainer được tối ưu hóa cho các mô hình dựa trên cây như XGBoost. TreeExplainer tính toán các giá trị Shapley chính xác bằng cách phân tích cấu trúc của cây quyết định trong quần thể, tránh lấy mẫu gần đúng cần thiết cho SHAP không xác định mô hình. Đối với mỗi cổng kiểm tra, SHAP tạo ra năm điểm phân bổ (một điểm cho mỗi tính năng) cho biết mức độ đóng góp của mỗi tính năng vào xác suất trojan được dự đoán so với dự đoán trung bình trên tất cả dữ liệu đào tạo.

Phân giải thích SHAP có dạng “LGF đã đóng góp +0,12 vào xác suất trojan” hoặc “PO đã đóng góp -0,08 vào xác suất trojan,” với các giá trị dương hướng tới phân loại trojan và giá trị âm hướng tới phân loại lành tính. Tổng của tất cả các giá trị SHAP bằng chênh lệch giữa xác suất dự đoán của cổng và xác suất cơ bản. Mặc dù SHAP cung cấp các phân bổ nghiêm ngặt về mặt toán học, giống như LIME, nó đưa ra các trọng số tính năng mà không cần diễn giải cấp độ mạch rõ ràng.

4.4.3 Gradient Attribution

Phân bổ tính năng dựa trên độ dốc sử dụng độ dốc của đầu ra của mô hình đối với các tính năng đầu vào để xác định các tính năng có ảnh hưởng. Kỹ thuật này, được giới thiệu bởi Simonyan et al. (2013) [3] để trực quan hóa học sâu, tính toán mức độ nhạy cảm của dự đoán của mô hình đối với những thay đổi nhỏ trong từng tính năng đầu vào. Các tính năng có cường độ gradient lớn ảnh hưởng mạnh đến dự đoán.

Đối với bộ phân loại XGBoost, việc phân bổ độ dốc được triển khai bằng cách tính toán độ dốc số thông qua sai phân hữu hạn. Đối với mỗi cổng kiểm tra có các tính năng $(f_1, f_2, f_3, f_4, f_5)$, mỗi tính năng f_i bị nhiễu bởi một giá trị lỗi nhỏ $\epsilon = 0.01$ để đo lường sự thay đổi trong xác suất trojan dự đoán: $g_i = \frac{\partial P(\text{trojan})}{\partial f_i} \approx \frac{P(f_1, \dots, f_i + \epsilon, \dots, f_5) - P(f_1, \dots, f_i, \dots, f_5)}{\epsilon}$. Vector gradient kết quả $(g_1, g_2, g_3, g_4, g_5)$ cho biết tầm quan trọng của đặc điểm.

Phân bổ gradient mang lại lợi thế về hiệu quả tính toán so với SHAP. Trong khi SHAP yêu cầu đánh giá mô hình trên nhiều tập hợp con tính năng theo cấp số nhân (được giảm thiểu bằng cách tối ưu hóa TreeExplainer), thì việc phân bổ độ dốc chỉ yêu cầu 5 đánh giá mô hình bổ sung (một đánh giá cho mỗi nhiễu loạn tính năng). Trong các thử nghiệm, phân bổ độ dốc đạt được hệ số tăng tốc là 7 so với SHAP, 0,16 mili giây (ms) so với 1,10 mili giây cho mỗi giải thích, đồng thời tạo ra cùng loại phân bổ tính năng. Chỉ riêng hiệu quả tính toán không giải quyết được hạn chế cơ bản của các phương pháp bất khả tri về mô hình: chúng thiếu bối cảnh cấp mạch bất kể thời gian tính toán.

5 Experimental Setup

Phần này mô tả tập dữ liệu, giao thức thử nghiệm và số liệu đánh giá để so sánh các phương pháp giải thích nhận biết miền và không xác định mô hình trong việc phát hiện trojan phần cứng.

5.1 Trust-Hub Benchmark Dataset

Quá trình đánh giá sử dụng 30 danh sách mạng cấp cổng, được mô tả trong Bảng 4, bắt nguồn từ 19 gói điểm chuẩn Trust-Hub [10, 11], một bộ dữ liệu được sử dụng rộng rãi cho nghiên cứu phát hiện trojan phần cứng. Trust-Hub cung cấp danh sách mạng Verilog tổng hợp với các phần chèn trojan đã biết, cho phép học có giám sát với các nhãn thông tin thực tế cho mỗi cổng. Ba mươi mạch bao gồm mười một thiết bị ngoại vi giao tiếp RS232 (mỗi mạch có các biến thể công nghệ 90nm và 180nm) và tám điểm chuẩn ISCAS:

Table 4: Các mạch Trust-Hub được đánh giá trong nghiên cứu này (30 mạch từ 19 gói điểm chuẩn)[11].

RS232-T1000_90nm	RS232-T1000_180nm	RS232-T1100_90nm
RS232-T1100_180nm	RS232-T1200_90nm	RS232-T1200_180nm
RS232-T1300_90nm	RS232-T1300_180nm	RS232-T1400_90nm
RS232-T1400_180nm	RS232-T1500_90nm	RS232-T1500_180nm
RS232-T1600_90nm	RS232-T1600_180nm	RS232-T1700_90nm
RS232-T1700_180nm	RS232-T1800_90nm	RS232-T1800_180nm
RS232-T1900_90nm	RS232-T1900_180nm	RS232-T2000_90nm
RS232-T2000_180nm	s15850-T100	s35932-T100
s35932-T200	s35932-T300	s38417-T100
s38417-T200	s38584-T100	s38584-T300

Ba mươi mạch thể hiện việc triển khai tổng hợp riêng biệt dựa trên kiểu đặt tên ô và đặc điểm cấu trúc. Mạch RS232 được cung cấp ở các biến thể công nghệ quy trình sản xuất 90 nanomet (nm) và 180nm (215-273 cổng mỗi mạch), trong khi điểm chuẩn ISCAS (s15850, s35932, s38417, s38584) sử dụng các thư viện ô khác nhau với số lượng cổng lớn hơn nhiều (2.115-7.204 cổng mỗi mạch). Các thư viện ô cổng logic tiêu chuẩn cụ thể không được ghi lại trong bản phân phối điểm chuẩn Trust-Hub. Sự đa dạng tổng hợp này cải thiện khả năng khái quát hóa mô hình trên các triển khai công nghệ khác nhau, ngăn chặn trình phân loại học các tạo phẩm dành riêng cho thư viện.

Năm đặc điểm cấu trúc được trích xuất từ mỗi cổng theo phương pháp của Hasegawa et al. [6, 7]: LGFi, FFi, FFO, PI và PO. Trích xuất tính năng được thực hiện bằng cách phân tích danh sách mạng Verilog bằng CircuitGraph [32] và xây dựng biểu diễn đồ thị có hướng với NetworkX [34] để truy vấn các thuộc tính cấu trúc của mỗi cổng.

Từ ba mươi mạch này, tổng cộng 56.959 cổng được trích xuất với các tính năng và nhãn liên quan. Tập dữ liệu thể hiện sự mất cân bằng cấp độ cực độ: 56.601 cổng lành tính (99,4%) so với 358 cổng trojan (0,6%), mang lại tỷ lệ mất cân bằng khoảng 158 trên một. Các mạch riêng lẻ có phạm vi từ hàng trăm đến hàng nghìn cổng, với số lượng trojan

thay đổi từ 2 đến 46 cổng trojan trên mỗi mạch bị nhiễm. Các quy trình triển khai chi tiết để xử lý dữ liệu, chuyển đổi thuộc tính và đào tạo mô hình được mô tả trong [38].

5.2 Train/Test Split and Evaluation Protocol

Ba giao thức đánh giá được sử dụng. Giao thức chính kết hợp tất cả ba mươi mạch và thực hiện phân chia đào tạo/xác nhận/kiểm tra ngẫu nhiên 60/20/20, phù hợp với phân chia được sử dụng bởi Hasegawa et al. trong đánh giá ban đầu của họ [6, 7]. Giao thức rời khỏi một mạch thứ cấp (LOCO) và giao thức rời khỏi một gia đình cấp ba (LOFO) cũng được báo cáo trong Phần 7 để mô tả khái quát hóa chéo mạch và xuyên họ tương ứng. Tỷ lệ chia 60/20/20 mang lại:

- **Training set:** 34.175 cổng (33.961 lành tính, 214 trojan; 60%)
- **Validation set:** 11.392 cổng (11.320 lành tính, 72 trojan; 20%)
- **Test set:** 11.392 cổng (11.320 lành tính, 72 trojan; 20%)

Ngưỡng được chọn để tối đa hóa F1 trên bộ xác thực. Bộ thử nghiệm được tổ chức hoàn toàn cho đến khi đánh giá cuối cùng. Sự phân chia ba chiều này giúp loại bỏ sai lệch lựa chọn ngưỡng phát sinh khi sử dụng cùng một dữ liệu cho cả điều chỉnh siêu tham số và báo cáo hiệu suất.

Tất cả năm phương pháp XAI (Dựa trên thuộc tính, Dựa trên trường hợp, LIME, SHAP, gradient) đều được đánh giá trên cùng một bộ thử nghiệm được tổ chức giống hệt nhau để cho phép so sánh công bằng. Kết quả được báo cáo trên bộ kiểm tra 11.392 cổng đầy đủ mà không cần lấy mẫu thêm, bao gồm tất cả các công kiểm tra trong đánh giá khả năng giải thích.

5.3 Evaluation Metrics

Hiệu suất phát hiện sử dụng các số liệu phân loại nhị phân tiêu chuẩn, độ chính xác $P = TP/(TP + FP)$, thu hồi $R = TP/(TP + FN)$, F_1 , tỷ lệ dương tính giả, AUPRC và MCC, theo Hasegawa et al. [6, 39–41]. Độ chính xác được báo cáo nhưng không được sử dụng làm thước đo chính: một trình phân loại hoàn toàn lành tính tầm thường đạt được độ chính xác 98,9% ở mức mất cân bằng trong tập kiểm tra 157:1, do đó độ chính xác và AUPRC là những số liệu mang tính thông tin vận hành.

Khả năng giải thích sử dụng sự tương ứng (dựa trên trường hợp: tỷ lệ k -hàng xóm gần nhất phù hợp với lớp được dự đoán), phạm vi thuộc tính (dựa trên thuộc tính: số lượng và tính đa dạng của các thuộc tính đóng góp), mối tương quan Spearman giữa xếp hạng tầm quan trọng của đặc điểm của các phương pháp phân bố khác nhau và thời gian tính theo đồng hồ treo tường cho mỗi lời giải thích. Kiểm tra định tính đầu ra được báo cáo cùng với các số liệu định lượng.

5.4 Implementation Details

Tất cả các phương thức đều được triển khai trong Python 3.12.3 bằng cách sử dụng scikit-learn 1.8.0 [42], XGBoost 3.1.2 [35], LIME 0.2.0.1 [1], SHAP 0.50.0 [2], CircuitGraph 0.2.0 [32] và Net-workX 2.6.3 [34]. Graphviz [43] được sử dụng để tạo ra các biểu diễn đồ thị trực quan của danh sách mạng mạch để kiểm tra và gỡ lỗi. Các thử nghiệm được chạy trên máy trạm Linux với bộ xử lý Intel Xeon và RAM 64GB. Các phép đo thời gian loại trừ việc tải tập dữ liệu và sử dụng thực thi đơn luồng để so sánh công bằng. Nguồn

mã và bộ dữ liệu được xử lý trước có sẵn tại https://github.com/paulwhitten/expl_phuong_phap_hw_mã_phát_hiện_trojan.

5.5 Statistical Analysis Protocol

Tất cả số liệu hiệu suất đều được báo cáo với khoảng tin cậy bootstrap là 95% (10.000 mẫu lại trên $n = 11,392$ cổng kiểm tra; mối tương quan Spearman bootstrap trên các cổng được so sánh), theo thông lệ đã được thiết lập để đánh giá ML không cân bằng [44, 45]. So sánh phân loại sử dụng thử nghiệm của McNemar trên các dự đoán theo cặp; so sánh tương quan giữa các phương pháp sử dụng Spearman ρ với các giá trị p được liên kết. Đối với các số liệu liên tục giữa các nhóm mạch, d của Cohen được báo cáo cùng với những khác biệt thô. Kết quả so sánh nhiều lần sử dụng hiệu chỉnh Bonferroni (α/k). Với 72 cổng trojan trong bộ kiểm tra, phân tích bootstrap hậu kiểm xác nhận rằng 95% TCTD có lỗi tiêu chuẩn dưới 2% đối với tất cả số liệu được báo cáo, đủ để phân biệt sự khác biệt giữa các phương pháp được quan sát.

6 Results

Phần này trình bày kết quả thử nghiệm đánh giá các phương pháp XAI được đề xuất để phát hiện trojan phần cứng. Năm phương pháp được so sánh: tập hợp dựa trên đặc tính của 31 bộ phân loại XGBoost (Phương pháp 1), kết hợp dựa trên trường hợp sử dụng XGBoost để phân loại với k-NN để giải thích (Phương pháp 2), giải thích LIME (Phương pháp 3), giải thích SHAP (Phương pháp 4) và phân bố độ dốc (Phương pháp 5). Tất cả các phương pháp đều sử dụng bộ phân loại XGBoost nhưng khác nhau về kiến trúc và cơ chế giải thích. Việc đánh giá tập trung vào hiệu suất phát hiện, ý nghĩa thống kê và các đặc điểm có thể giải thích được.

Tất cả các thử nghiệm đều được tiến hành trên tập dữ liệu điểm chuẩn Trust-Hub với tổng số 56.959 mẫu (34.175 mẫu đào tạo, 11.392 xác nhận, 11.392 thử nghiệm), bắt nguồn từ 30 mạch chứa trojan phần cứng. Ngưỡng đã được chọn trên bộ xác thực. Tất cả số liệu được báo cáo là từ bộ thử nghiệm được tổ chức. Xác thực thống kê sử dụng khoảng tin cậy của bootstrap với 10.000 lần lặp và kiểm tra McNemar để so sánh theo cặp.

6.1 Binary Classification Performance

6.1.1 Optimized XGBoost Performance

Trình phân loại XGBoost (được sử dụng bởi Phương pháp 2–5) đã đạt được mức thu hồi cao nhất ở ngưỡng phân loại tối ưu giá trị là 0,940. Ở ngưỡng này trong bộ kiểm tra được tổ chức, độ chính xác đạt 48,08% với tỷ lệ thu hồi là 69,44%, mang lại điểm F1 là 0,568 và MCC là 0,575. Ma trận nhầm lẫn cho thấy 11.266 kết quả âm tính thật, 54 kết quả dương tính giả, 22 kết quả âm tính giả và 50 kết quả dương tính thật, mang lại độ chính xác 99,33%. AUPRC trên bộ thử nghiệm là 0,637, cao hơn $101\times$ so với mức cơ bản không có kỹ năng là 0,0063 với mức độ phổ biến của lớp là 0,63%.

So với ngưỡng cơ bản là 0,5, ngưỡng được tối ưu hóa đã mang lại những cải tiến: độ chính xác tăng từ 11,85% lên 48,08% (+305,5%), điểm F1 được cải thiện từ 0,2069 lên 0,568 (+174,4%) và kết quả dương tính giả giảm 403 trường hợp

(giảm 88,2%). Trong cùng điều kiện thử nghiệm (tách 60/20/20 giống hệt nhau, năm tính năng Hasegawa), việc triển khai lại SVM đạt được độ chính xác 11,33% ở ngưỡng 0,050, do đó XGBoost thể hiện mức cải thiện độ chính xác gấp 4,25 lần (táo với táo) và giảm 7,4 lần mật độ dương tính giả (4,74 so với 35,0 FP trên 1.000 công).

6.1.2 Method Comparison

Bảng 5 so sánh tất cả năm phương pháp về hiệu suất phân loại, phạm vi có thể giải thích và hiệu quả tính toán. M1 là một tập hợp tài sản độc lập gồm 31 thành viên. M2–M5 chia sẻ một trình phát hiện XGBoost duy nhất (độ chính xác 99,33%, ngưỡng = 0,940) và chỉ khác nhau ở phần phụ trợ giải thích hậu kỳ được đính kèm với nó. Do đó, bảng này tách biệt những khác biệt về cơ chế giải thích với những khác biệt về phân loại đối với M2–M5.

M1 (tập hợp tài sản) đào tạo 31 bộ phân loại XGBoost riêng biệt, mỗi bộ phân loại dựa trên sự kết hợp khác nhau của 5 tính năng mạch, sau đó tổng hợp các dự đoán thông qua bỏ phiếu có trọng số. Như được báo cáo trong Bảng 5, tập hợp có trọng số E_{PARS} đạt được độ chính xác 67,7% và khả năng thu hồi 88,9% nhưng chỉ có độ chính xác 1,7% ở ngưỡng mặc định, với độ tin cậy biểu quyết trung bình là 0,4272 và mức độ bao phủ giải thích 100%. Để phân biệt mức trần cơ bản của việc liệt kê thuộc tính với sự giả tạo của lựa chọn trọng số và ngưỡng, chúng tôi đã tổng hợp lại 31 bộ phân loại đã được đào tạo giống nhau bằng cách sử dụng trọng số xác thực-MCC ($w_i = \max(\text{MCC}_i, 0)$), tất cả 31 bộ phân loại được giữ lại) và điều chỉnh ngưỡng biểu quyết trên bộ xác thực. Ở ngưỡng val-tối ưu ($t = 0.799$), tổ hợp có trọng số MCC đạt $P = 78.1\%$, $R = 34.7\%$, $F1 = 0.481$, $\text{MCC} = +0.519$, $\text{AUPRC} = 0.393$ và 0,6 FP trên 1.000 công trên bộ thử nghiệm được tổ chức, cạnh tranh với M2–M5 về độ chính xác và mật độ dương tính giả với chi phí thu hồi. Do đó, kết quả có độ chính xác thấp nằm trong phạm vi cấu hình có trọng số E_{PARS} ở ngưỡng mặc định: nó phản ánh phương pháp phỏng đoán trọng số của Phương pháp 1 đã được công bố, chứ không phải là giới hạn cố hữu của việc liệt kê thuộc tính có thể giải thích được đối với năm tính năng của Hasegawa. Việc liệt kê tổ hợp vẫn cung cấp mức độ phong phú ngữ nghĩa hạn chế so với các phép biến đổi nhận biết miền kết hợp các mối quan hệ cấp mạch và các kết hợp tính năng như LGFi-FFi-PO phù hợp với các nguyên tắc thiết kế trojan phần cứng mà các kỹ sư bảo mật thường xuyên áp dụng trong quá trình phân tích mạch thủ công. Phát hiện này phù hợp với nghiên cứu trước đây [38] thừa nhận rằng “rất khó để ánh xạ khái niệm về một thuộc tính có thể giải thích được với tập hợp tính năng tối thiểu”; kết quả được tính theo trọng số MCC bổ sung làm rõ rằng “khả năng giải thích có giới hạn” được dàn xếp bằng việc lựa chọn trọng số tổng hợp và điểm vận hành.

M2 (k-NN dựa trên trường hợp) sử dụng kiến trúc kết hợp: XGBoost đưa ra quyết định phân loại, sau đó hệ thống truy xuất k=5 lân cận gần nhất từ tập huấn luyện để đưa ra giải thích dựa trên trường hợp. Điều này đạt được sự tương ứng trung bình 96,51% giữa dự đoán XGBoost và phiếu bầu k-NN theo trọng số khoảng cách (cụ thể là 75,28% đối với công trojan), thể hiện sự liên kết chặt chẽ giữa bộ phân loại và tiền lệ giải thích. Không giống như các kết hợp thuộc tính dành riêng cho miền của M1, M2 cung cấp các giải thích trực quan thông qua các mẫu đào tạo cụ thể. Các lân cận được truy xuất bao gồm nguồn gốc danh sách mạng hoàn chỉnh (tên mạch, phiên bản, số dòng, tên mạng), vì vậy các kỹ sư có thể kiểm tra các ví dụ đào tạo thực tế và xác minh sự tương đồng về cấu trúc, một hình thức giải thích yêu cầu diễn giải theo miền cụ thể ở mức tối thiểu.

M2-M5 sử dụng kiến trúc phân loại XGBoost giống hệt nhau (độ chính xác 99,33%), nghĩa là chúng tạo ra các dự đoán giống hệt nhau trên bộ thử nghiệm. Các phương pháp này chỉ khác nhau ở cách tiếp cận khả năng giải thích hậu kiểm: M2 truy xuất k mẫu huấn luyện lân cận gần nhất để giải thích dựa trên trường hợp, M3 (LIME) sử dụng xấp xỉ tuyến tính cục bộ dựa trên nhiễu loạn, M4 (SHAP) sử dụng các giá trị Shapley lý thuyết trò chơi và M5 (phân bổ độ dốc) tính toán độ dốc số cho tầm quan trọng của đặc điểm. Sự tương đương về kiến trúc này giải thích tại sao M2-M5 hiển thị các ma trận nhầm lẫn giống hệt nhau trong Bảng 5: phương pháp giải thích không ảnh hưởng đến các quyết định phân loại, chỉ có các diễn giải được cung cấp cho người dùng.

M3 (LIME), M4 (SHAP) và M5 (Gradient) đều đạt mức độ bao phủ 100% trên bộ thử nghiệm, tạo ra lời giải thích cho tất cả 11.392 mẫu bao gồm tất cả 72 trường hợp trojan. M5 thể hiện thời gian giải thích nhanh nhất ở mức 0,16 mili giây trên mỗi mẫu (hệ số tăng tốc là 150 so với LIME), trong khi M4 ở mức 1,10 mili giây trên mỗi mẫu cung cấp hệ số tăng tốc là 22 so với 24,4 mili giây trên mỗi mẫu của M3.

6.1.3 Random Forest Classifier Performance

Rừng ngẫu nhiên (500 công cụ ước tính, `class_weight='balanced'`) được đánh giá là công cụ phân loại thứ hai để đánh giá liệu các phát hiện XAI có khái quát hóa ngoài XGBoost hay không. Ở ngưỡng giá trị tối ưu là 0,820, Random Forest đạt được trên bộ thử nghiệm được tổ chức: độ chính xác 58,46%, thu hồi 52,78%, $F1 = 0,555$, $MCC = 0,553$, $AUPRC = 0,512$. Ma trận nhầm lẫn hiển thị 11.293 kết quả âm tính thật, 27 kết quả dương tính giả, 34 kết quả âm tính giả và 38 kết quả dương tính thật (độ chính xác 99,46%).

Rừng ngẫu nhiên tạo ra một nửa mật độ dương tính giả của XGBoost (2,37 so với 4,74 FP trên 1.000 công) với chi phí thu hồi thấp hơn (52,78% so với 69,44%). Sự cân bằng của người thực hiện là: sử dụng XGBoost khi thu hồi là ưu tiên (các ứng dụng quan trọng về trojan trong đó việc phát hiện thiếu sẽ gây tổn kém nghiêm trọng) và Rừng ngẫu nhiên khi gánh nặng của nhà phân tích dương tính giả là ràng buộc ràng buộc.

Bảng xếp hạng tầm quan trọng của tính năng từ XGBoost và Random Forest cho thấy sự đồng thuận mạnh mẽ trên cả bốn quan điểm giải thích (XGBoost SHAP, RF SHAP, XGBoost LIME, RF LIME): PO, FFO và LGFi luôn chiếm vị trí top 3 trên tất cả các phương pháp và cả hai phân loại. Spearman xếp hạng tính năng $\rho_s = 0.800$ (XGBoost so với RF SHAP) và $\rho_s = 0.600$ (XGBoost so với RF LIME) trên $n = 5$ tính năng mang tính mô tả nhưng không đủ mạnh để kiểm tra mức độ quan trọng (yêu cầu mức tối thiểu có thể đạt được $p \approx 0.008$ $\rho_s = 1.000$ với $n = 5$).

Để đưa ra so sánh hợp lệ về mặt thống kê, mối tương quan Spearman ở cấp độ công giữa các giá trị XGBoost và RF SHAP đã được tính toán trên tất cả 11.392 công thử nghiệm. Cả 5 đặc điểm đều thể hiện sự đồng tình cao ($p < 10^{-300}$): PO ($\rho_s = 0.816$), PI ($\rho_s = 0.773$), LGFi ($\rho_s = 0.666$), FFi ($\rho_s = 0.664$), FFO ($\rho_s = 0.587$). Tương quan cấp công sum-SHAP là $\rho_s = 0.511$ ($p < 10^{-300}$). Điều này xác nhận rằng các công riêng lẻ giống nhau nhận được trọng số có thể giải thích cao theo cả hai phân loại, chứng minh rằng các phát hiện XAI mang tính bất khả tri về phân loại hơn là đặc trưng cho XGBoost.

6.1.4 E_{PARS} Ensemble Weighting Criterion vs. MCC

E_{PARS} (Hiệu quả là sản phẩm của Độ chính xác, Độ chính xác, Độ thu hồi và Độ đặc hiệu [36]) là một tiêu chí trọng số tổng hợp được sử dụng để chọn trọng số phân loại cho đa số

bỏ phiếu trong Phương pháp 1. Đây là sản phẩm của bốn chỉ số phân loại:

$$\begin{aligned}
E_{PARS} &= P \cdot A \cdot R \cdot S \\
&= \frac{TP}{TP + FP} \cdot \frac{TP + TN}{N} \cdot \frac{TP}{TP + FN} \cdot \frac{TN}{TN + FP} \\
&= \frac{TN \cdot TP^2 (TP + TN)}{(TN + FP)(TP + FP)(TP + FN) \cdot N}
\end{aligned} \tag{3}$$

trong đó TP, TN, FP, FN được tính toán trên bộ xác thực và $N = TP + TN + FP + FN$. E_{PARS} được giới hạn ở $[0, 1]$ và bằng 0 bất cứ khi nào bất kỳ chỉ số nào trong bốn chỉ số thành phần bằng 0, đảm bảo rằng các bộ phân loại có độ chính xác, độ chính xác, khả năng thu hồi hoặc độ đặc hiệu kém sẽ nhận được trọng số bằng 0 trong tổng thể.

Để đánh giá liệu thứ hạng E_{PARS} có phù hợp với chất lượng phân loại dựa trên thực tế (MCC) hay không, mối tương quan thứ hạng Spearman đã được tính toán giữa E_{PARS} và MCC trên tất cả 31 bộ phân loại thuộc tính trên bộ xác thực. Kết quả là $\rho_s = 0.5403$ ($p = 0.0017$), biểu thị mức độ đồng ý vừa phải nhưng có ý nghĩa thống kê: các bộ phân loại E_{PARS} xếp hạng cao có xu hướng có giá trị MCC cao hơn nhưng sự tương ứng không hoàn hảo.

Có sự khác biệt mang tính hệ thống giữa hai bảng xếp hạng. E_{PARS} ưu tiên các bộ phân loại một và hai đặc điểm vì các bộ phân loại đơn giản hơn đạt được tỷ lệ FP thấp hơn trên lớp lành tính đa số. 5 bộ phân loại hàng đầu theo E_{PARS} là sự kết hợp một hoặc hai tính năng: FFO, PO, LGFi+PO, FFO+PO và PI+PO (tất cả $E_{PARS} = 0,571$). Top 5 của MCC đều là sự kết hợp từ ba đến bốn tính năng: LGFi+FFi+FFo+PO (MCC = 0,418), FFO+PI+PO (0,405), FFi+FFo+PO (0,402), LGFi+FFo+PI (0,348) và LGFi+FFo+PO (0,334). Hai danh sách không có thành viên nào.

Sự khác biệt này xác nhận rằng E_{PARS} hoạt động như một phương pháp suy nghiệm trọng số tổng hợp chứ không phải là thước đo hiệu suất cho mục đích chung và được thừa nhận là dư thừa một phần với độ chính xác trong chế độ lớp cân bằng [36]. MCC là thước đo ưa thích để đánh giá chất lượng phân loại thuộc tính riêng lẻ; E_{PARS} được giữ lại làm cơ chế tính trọng số của Phương pháp 1 vì về mặt thực nghiệm nó làm giảm các kết quả dương tính giả trong phiếu bầu tổng hợp.

6.1.5 Classifier Comparison with SVM Baseline

Bảng 6 so sánh cả ba bộ phân loại: XGBoost, Rừng ngẫu nhiên và đường cơ sở SVM bằng cách sử dụng năm tính năng và nhân RBF của Hasegawa trên bộ thử nghiệm được tổ chức. Giá trị in đậm cho biết hiệu suất tốt nhất cho từng số liệu.

Cả hai bộ phân loại tập hợp cây đều hoạt động tốt hơn đáng kể so với đường cơ sở SVM trên F1 và MCC. SVM tạo ra 35,0 FP trên 1.000 công — một mức độ lớn hơn cả XGBoost (4,74) và Rừng ngẫu nhiên (2,37) — khiến SVM không thể triển khai ở cấp công. FPR được công bố của SVM khoảng 50,5% [6] không được sao chép khi triển khai lại (3,52% ở ngưỡng 0,050), phù hợp với tập dữ liệu lớn hơn (30 so với 15 mạch) làm thay đổi hiệu chuẩn xác suất SVM.

Table 6: So sánh phân loại trên bộ thử nghiệm được tổ chức (11.392 công, 72 trojan). Tất cả ba bộ phân loại đều sử dụng cùng năm đặc điểm cấu trúc Hasegawa, cùng mức phân chia 60/20/20 (trạng thái ngẫu nhiên=42) và các ngưỡng được chọn để tối đa hóa F1 trên bộ xác thực. SVM: nhân `RBF, class_weight='balanced'`.

Metric	XGBoost	Random Forest	SVM
Val-optimal threshold	0.940	0.820	0.050
Precision (%)	48.08	58.46	11.33
Recall (%)	69.44	52.78	70.83
F1	0.568	0.555	0.195
MCC	0.575	0.553	0.274
AUPRC	0.637	0.512	—
FP / 1,000 gates	4.74	2.37	35.0
Recall @ FPR ≤ 0.1%	55.56%	34.72%	—
Recall @ FPR ≤ 0.5%	69.44%	55.56%	—
TP / FP / FN / TN	50/54/22/11,266	38/27/34/11,293	51/399/21/10,921

6.1.6 Precision-Recall Curve and AUPRC

Đường cong thu hồi chính xác (PR) mô tả hiệu suất của máy dò trên tất cả các ngưỡng vận hành mà không cần giả định một điểm vận hành cụ thể và là số liệu tóm tắt thích hợp để phân loại mất cân bằng nghiêm trọng [41]. Đường cong PR cho XGBoost và Rừng ngẫu nhiên trên bộ thử nghiệm có sẵn ở `data/models/method2/pr_curve.json` (99 mức ngưỡng, 0,01–0,99 bước 0,01).

XGBoost đạt được $AUPRC = 0,637$ ($101 \times$ trên mức cơ bản dành cho người không có kỹ năng là 0,0063 với tỷ lệ phổ biến trong nhóm là 0,63%). Rừng ngẫu nhiên đạt $AUPRC = 0,512$ ($81 \times$ so với đường cơ sở). Các báo cáo trong Bảng 7 gọi lại ngân sách về tỷ lệ dương tính giả cố định, một thước đo có động cơ thực tế; các nhóm báo mật thường làm việc trong điều kiện hạn chế về năng lực của nhà phân tích được biểu thị bằng “nhiều nhất k cảnh báo sai trên 1.000 công được kiểm tra”.

Table 7: Thu hồi ở mức trần tỷ lệ dương tính giả (FPR) cố định, bộ thử nghiệm. Ở $FPR \leq 0.1\%$, tối đa 11 công lành tính được gắn cờ trên mỗi bộ kiểm tra 11.392 công.

FPR ceiling	XGB recall	XGB threshold	RF recall	RF threshold
$\leq 0.1\%$ (1 in 1,000)	55.56%	0.986	34.72%	0.954
$\leq 0.5\%$ (5 in 1,000)	69.44%	0.931	55.56%	0.749
$\leq 1.0\%$ (10 in 1,000)	69.44%	0.873	56.94%	0.701

Với ngân sách FPR eo hẹp nhất ($\leq 0.1\%$), XGBoost phát hiện 55,6% trojan trong khi tạo ra tối đa 11 kết quả dương tính giả trên 11.392 công. Rừng ngẫu nhiên tụt lại đáng kể ở điểm vận hành này (34,7%), vì khối lượng xác suất của nó tập trung ở các giá trị độ tin cậy thấp hơn. Ở $\leq 0.5\%$ FPR, XGBoost đạt đến điểm vận hành giá trị tối ưu (khả năng thu hồi 69,4%). Rừng ngẫu nhiên đạt 55,6%. Cả hai mẫu đều không cải thiện khả năng thu hồi hơn nữa ở mức 1,0% FPR. Các trojan bị bỏ sót còn lại yêu cầu ngưỡng dưới ngân sách FPR 1%.

6.1.7 Per-Circuit Breakdown

Bảng 8 phân tích hiệu suất phát hiện XGBoost (ngưỡng 0,940) theo mạch riêng lẻ. Mười chín trong số ba mươi mạch bị bỏ qua vì sự phân chia phân tầng 60/20/20 trên toàn bộ nhóm 56.959 công phân phối trojan một cách mỏng trên các biến thể mạch RS232 nhỏ hơn, để lại ít hơn ba công mang trojan trong phần thử nghiệm cho các mạch đó. Độ chính xác và thu hồi trên mỗi mạch không ổn định về mặt số lượng dưới mức này. Mười một mạch có thể báo cáo trải dài ba trong số năm dòng mạch Trust-Hub (RS232, s15850, s35932, s38417).

Table 8: Hiệu suất XGBoost trên mỗi mạch (ngưỡng 0,940). Các mạch có ít hơn 3 công trojan được thiết lập thử nghiệm sẽ bị bỏ qua (19 trên 30). Sự phân chia phân tầng 60/20/20 phân phối trojan một cách thừa thớt trên các biến thể nút quy trình RS232 riêng lẻ.

Circuit	Tech	TP	FP	FN	Prec.	Rec.	F1
RS232-T1000	90nm	1	0	2	1.000	0.333	0.500
RS232-T1100	180nm	3	1	1	0.750	0.750	0.750
RS232-T1200	180nm	3	0	1	1.000	0.750	0.857
RS232-T1400	90nm	4	1	0	0.800	1.000	0.889
RS232-T1900	180nm	3	0	4	1.000	0.429	0.600
RS232-T1900	90nm	1	0	2	1.000	0.333	0.500
RS232-T2000	90nm	2	0	1	1.000	0.667	0.800
s15850-T100	180nm	7	0	1	1.000	0.875	0.933
s35932-T300	180nm	6	13	3	0.316	0.667	0.429
s38417-T100	180nm	3	5	0	0.375	1.000	0.545
s38417-T200	180nm	2	6	1	0.250	0.667	0.364

Các mạch RS232 cho thấy độ chính xác cao đồng đều (0,750–1,000), phản ánh tính đều đặn về cấu trúc của trojan giao diện nối tiếp. Việc thu hồi rất khác nhau (0,333–1,000) do số lượng trojan khan hiếm trong lần thử nghiệm. Các mạch tổ hợp lớn hơn (s35932-T300, s38417-T100/T200) cho thấy độ chính xác thấp hơn (0,250–0,375) nhưng khả năng thu hồi cao hơn, phù hợp với tính đa dạng về tính năng lớn hơn và nhiều sự chồng chéo ranh giới quyết định hơn giữa trojan và công lành tính trong các thiết kế giàu công. Mạch s15850-T100 đạt kết quả mạnh nhất ($P=1.000$, $R=0.875$, $F1=0.933$).

Ở ngưỡng cơ bản là 0,5, độ chính xác của XGBoost là 11,85% với tỷ lệ thu hồi khoảng 82%, chứng tỏ tính không ổn định của phân loại không được tối ưu hóa trên tập dữ liệu mất cân bằng nghiêm trọng này. Ở ngưỡng giá trị tối ưu là 0,940, độ chính xác được cải thiện lên 48,08% và tỷ lệ thu hồi lên 69,44%, với $F1 = 0,568$ và $MCC = 0,575$ trên bộ thử nghiệm được tổ chức.

Kiểm tra chi bình phương của McNemar so sánh Phương pháp 1 (tổ hợp) với Phương pháp 2 (XGBoost đơn) mang lại $\chi^2(1) = 3578.23$ ($p < 0.001$). Số liệu thống kê lớn một phần được thúc đẩy bởi $n = 11,392$. Kích thước hiệu ứng xác nhận tầm quan trọng thực tế: 3622 cặp chỉ đúng M2 so với 14 cặp trái ngược chỉ đúng M1, khoảng cách chính xác 31,6 điểm phần trăm (99,33% ở ngưỡng tối ưu hóa so với 67,7%). Phương pháp 2–5 chia sẻ các dự đoán giống hệt nhau (cùng một bộ phân loại, các cách giải thích khác nhau), do đó, so sánh kiểm tra chéo giữa chúng sẽ đo lường phạm vi có thể giải thích và hiệu quả tính toán chứ không phải độ chính xác của phân loại.

6.2 Explainability Analysis

6.2.1 Feature Importance Rankings

Phương pháp LIME và SHAP cho thấy các mẫu đặc điểm quan trọng nhất quán để phát hiện trojan. Đối với XGBoost: Các tính năng được xếp hạng hàng đầu của LIME (theo tần suất xếp hạng số 1) là: PO (38,5%), FFO (26,7%), LGFi (22,3%), PI (10,8%) và FFi (1,7%). Các tính năng hàng đầu của SHAP (theo giá trị SHAP tuyệt đối trung bình) là: PO (4.1071), LGFi (3.4160), FFO (2.8944), PI (1.9109) và FFi (1.4086).

Đối với Rừng ngẫu nhiên: Tần suất xếp hạng top 1 của LIME là FFO (98,5%), PO (1,5%). Các giá trị tuyệt đối trung bình của SHAP là PO (0,156), FFO (0,127), LGFi (0,125), FFi (0,046), PI (0,043). Trong tất cả bốn chế độ xem có thể giải thích (XGBoost SHAP, RF SHAP, XGBoost LIME, RF LIME), PO, FFO và LGFi đều chiếm ba vị trí hàng đầu, chỉ có thứ tự tương đối của FFO và PO khác nhau giữa các phân loại.

6.2.2 Explanation Coverage and Computational Efficiency

Các phương pháp dựa trên thuộc tính (Phương pháp 1) đã tạo ra các kết hợp thuộc tính có thể hiểu được cho mọi mẫu thử nghiệm mà không cần thêm chi phí tính toán, đạt được phạm vi giải thích đầy đủ. Các phương pháp bất khả tri về mô hình (LIME và SHAP) yêu cầu tạo hậu kỳ nhưng đã đạt được phạm vi bao phủ đầy đủ với các yêu cầu tính toán thực tế.

Việc triển khai TreeExplainer của SHAP đã khai thác cấu trúc cây của các mô hình XGBoost để đạt được hệ số tăng tốc 22 so với phương pháp tiếp cận dựa trên nhiễu loạn của LIME. Đối với bộ thử nghiệm 11.392 mẫu, SHAP yêu cầu tổng thời gian giải thích khoảng 13 giây so với 278 giây của LIME, giúp SHAP phù hợp hơn với các kịch bản triển khai sản xuất yêu cầu tạo giải thích theo thời gian thực hoặc gần thời gian thực.

6.3 Discussion

Lựa chọn ngưỡng được tối ưu hóa (0,940) cải thiện hiệu suất phát hiện trojan, chuyển đổi XGBoost từ bộ phân loại có khả năng thu hồi cao nhưng độ chính xác thấp (đường cơ sở: $\approx$ thu hồi 82%, độ chính xác 11,85%) thành máy phát hiện cân bằng hơn (thu hồi 69,44%, độ chính xác 48,08%). Việc tối ưu hóa ngưỡng này đánh đổi một số lần thu hồi để cải thiện độ chính xác gấp 4,1 lần, giảm mật độ dương tính giả từ ≈ 40 xuống 4,74 FP trên 1.000 công.

Sự tương phản giữa các phương pháp tiếp cận khả năng giải thích dựa trên thuộc tính và dựa trên trường hợp (trọng số M1 trong E_{PARS} đạt được khả năng thu hồi 88,9% nhưng chỉ có độ chính xác 1,7%, cùng 31 phân loại được tổng hợp lại với trọng số val-MCC đạt độ chính xác 78,1% ở mức thu hồi 34,7% (ngưỡng tối ưu hóa giá trị) và M2 đạt được khả năng thu hồi 69,44% với độ chính xác 48,08%) thúc đẩy sự kết hợp các hệ thống kết hợp khả năng diễn giải vốn có của tập hợp thuộc tính để giải thích có phạm vi bao phủ cao với các phương pháp bất khả tri về mô hình để giải thích các bộ phân loại hiệu suất cao hơn. Hệ số tăng tốc 22 của SHAP so với LIME khiến nó trở thành phương pháp giải thích bất khả tri về mô hình được ưa thích cho quy trình phát hiện trojan thực tế.

So với đường cơ sở Hasegawa SVM được triển khai lại trong các điều kiện giống hệt nhau (độ chính xác 11,33% ở ngưỡng 0,050, 35,0 FP trên 1.000 công), các phương pháp tăng cường độ dốc hiện đại với tối ưu hóa ngưỡng cẩn thận sẽ đạt được những cải tiến đáng kể về độ chính xác (4,25 lần, XGBoost) đồng thời giảm mật độ dương tính giả (7,4 lần đối với XGBoost, 14,8 lần đối với Rừng ngẫu nhiên). Việc thu hồi XGBoost (69,44%)

có thể so sánh với đường cơ sở SVM (70,83%), đồng thời đạt được độ chính xác cao hơn đáng kể. Năm tính năng Hasegawa tương tự được giữ lại để cho phép so sánh trực tiếp và duy trì các đặc tính mạch có thể hiểu được.

6.3.1 Property-Based Explainability in Low-Dimensional Settings

Độ chính xác được công bố của phương pháp dựa trên thuộc tính (M1: 1,7% trong E_{PARS} trọng số ở ngưỡng mặc định so với M2–M5: 48,08%) phản ánh sự lựa chọn trọng số tổng hợp và điểm vận hành, chứ không phải mức trần tuyệt đối về khả năng giải thích nhận biết miền trong các miền bị ràng buộc về tính năng. Việc tổng hợp lại 31 bộ phân loại đã được đào tạo tương tự với trọng số val-MCC ở ngưỡng val-tối ưu mang lại độ chính xác 78,1% với mức thu hồi 34,7% (xem Bảng 5). Việc thu hồi vẫn là yếu tố hạn chế đối với việc liệt kê tài sản chỉ dựa trên năm đặc điểm cấu trúc. Nhóm gồm 31 thành viên vẫn thiếu sự phong phú về ngữ nghĩa cần thiết để khôi phục đồng thời khả năng phát hiện có độ thu hồi cao, độ chính xác cao và các kiến trúc AI có thể giải thích được trên các bộ tính năng tối thiểu không thể chỉ dựa vào phép liệt kê tổ hợp để vượt qua biên giới đó.

Ba hướng có thể tăng cường khả năng giải thích dựa trên đặc tính trong cài đặt chiều thấp: các thuộc tính tỷ lệ mã hóa các mối quan hệ miền dưới dạng thương số đặc tính (LGF_i/PO, PI/PO, FFi/FFo) tương ứng với các khái niệm như “độ phức tạp của fanin gần đầu ra” hoặc “sự bất đối xứng cách ly flip-flop”; các thuật ngữ tương tác nắm bắt các mối quan hệ theo cặp (LGF_i · FFO, PI · LGF_i) gắn liền với tải trọng và các mẫu kích hoạt; và các tính năng phân vị tương đối của mạch (ví dụ: LGF_i phân vị thứ 95 trong một mạch) để phát hiện sự kiện hiếm gặp trên các thiết kế không đồng nhất.

Những phép biến đổi này phù hợp với quan sát [38] rằng các phương pháp dựa trên thuộc tính hoạt động tốt nhất với dữ liệu có chiều cao, trong khi các phương pháp dựa trên trường hợp lại vượt trội trong cài đặt chiều thấp. Các kết quả hiện tại xác nhận sự cân bằng này: kết hợp dựa trên trường hợp của M2 đạt được cả độ chính xác 99,33% / độ chính xác 48,08% và độ tương ứng 96,51%; đối với các bộ tính năng tối thiểu, việc kết hợp ML bất khả tri theo miền với các giải thích dựa trên tiên lệ sẽ hiệu quả hơn so với việc bỏ phiếu tập hợp thuộc tính.

6.3.2 Computational Efficiency Tradeoffs: Gradient vs. SHAP Attribution

Phân bổ độ dốc (M5) yêu cầu sáu đánh giá mô hình cho mỗi mẫu (đường cơ sở cộng với một nhiễu loạn sai phân hữu hạn cho mỗi tính năng ở $\epsilon = 0.01$), mang lại 0,16 mili giây cho mỗi giải thích so với 1,10 mili giây của SHAP (TreeExplainer trên các liên minh đối tượng) và 24,4 mili giây của LIME. Trong bộ kiểm tra 11.392 công, quá trình chạy từ đầu đến cuối mất 1,9 giây đối với độ dốc so với 13 giây đối với SHAP, một biên độ gộp trên danh sách mạng triệu công.

Tốc độ phải trả giá bằng sự đảm bảo tính nhất quán và độ chính xác cục bộ của SHAP: phân bổ độ dốc là các xấp xỉ tuyến tính cục bộ, được xác định rõ trong từng vùng lá XGBoost không đổi từng phần nhưng gần đúng ở ranh giới quyết định và nhạy cảm với việc lựa chọn ϵ . SHAP là mặc định phù hợp khi đảm bảo chính thức hoặc ghi công chất lượng xuất bản là quan trọng; gradient là mặc định phù hợp cho sàng lọc lần đầu dưới mili giây, với tùy chọn kết hợp cả hai (phân loại gradient rồi SHAP trên các công được gắn cờ). Dù bằng cách nào, điểm quan trọng chung của cả hai phương pháp vẫn cần bối cảnh miền (“đầu ra gần fanin cao biểu thị các mạch kích hoạt”) để thúc đẩy

xác nhận và khắc phục, thúc đẩy việc so sánh dựa trên đặc tính và trường hợp trong bài viết này.

7 Limitations and Future Work

Năm hạn chế ràng buộc phạm vi của công việc này.

Đầu tiên, việc đánh giá bị giới hạn ở điểm chuẩn Trust-Hub với các phần chèn trojan tổng hợp: trojan kết hợp kỹ thuật số trong danh sách mạng cấp công, ngoại trừ các mối đe dọa ở cấp độ hệ thống/tín hiệu tương tự/hỗn hợp, kích hoạt tuần tự và cấp hệ thống. Sự đa dạng tổng hợp trên các thư viện ô tiêu chuẩn được bao gồm, nhưng các mạch là điểm chuẩn học thuật. Các trojan ở giai đoạn chế tạo thực sự có thể mang các dấu hiệu cấu trúc khác nhau và yêu cầu xác thực trên các thiết kế được triển khai khi các bộ dữ liệu đó tồn tại. Thứ hai, biểu diễn năm tính năng nắm bắt cấu trúc nhưng bỏ qua các chữ ký chức năng, thời gian và công suất cung cấp các tín hiệu phát hiện bổ sung. Thứ ba, sự mất cân bằng lớp cực độ (157 trên một trong bộ thử nghiệm) khiến 30,56% trojan không bị phát hiện với tỷ lệ thu hồi 69,44% và thúc đẩy các kỹ thuật phát hiện bổ sung để đảm bảo phạm vi bảo mật hoàn chỉnh. Thứ tư, việc đánh giá báo cáo các số liệu định lượng và kiểm tra định tính thay vì các nghiên cứu có kiểm soát đối tượng con người với các kỹ sư bảo mật đang hành nghề, hạn chế các kết luận về khả năng diễn giải và độ tin cậy trong thế giới thực [27, 46].

Thứ năm, và quan trọng đối với việc xác định sự đóng góp: xác thực chéo loại bỏ một mạch (LOCO) được thực hiện theo giao thức ban đầu của Hasegawa và cộng sự [6]: mỗi mạch trong số 30 mạch được tổ chức lần lượt; mô hình được huấn luyện trên 29 phần còn lại và được thử nghiệm trên tất cả các công của mạch được tổ chức. Kết quả cho thấy một cấu trúc hai chế độ.

Trong họ mạch RS232 (22 nếp gấp, tất cả các biến thể máy thu-phát không đồng bộ phổ quát (UART) đều có chung kiến trúc cơ bản), LOCO khá quát hóa tốt: $F1 = 0,80$ trung bình vi mô ($P = 0,79$, $R = 0,82$, $MCC = 0,82$). $F1$ trên mỗi mạch dao động từ 0,53 đến 1,00. Điều này xác nhận rằng năm tính năng ghi lại các dấu hiệu trojan thực sự trong bối cảnh kiến trúc cố định.

Trên các mạch điểm chuẩn ISCAS (8 lần: s15850, s35932, s38417, s38584), việc khái quát hóa không thành công: $F1 = 0,06$ trung bình vi mô ($P = 0,04$, $R = 0,06$). $F1$ trên mỗi mạch dao động từ 0,00 đến 0,25. Năm đặc điểm vô hướng (LGF_i, FFi, FFO, PI, PO) là khoảng cách tổng hợp mạch-toàn cầu. Giá trị tuyệt đối của chúng bị chi phối bởi kích thước tổng thể và khả năng kết nối của netlist, khác biệt đáng kể giữa các dòng chuẩn khác nhau về mặt kiến trúc. Các phương pháp có biểu diễn đồ thị cục bộ phong phú hơn [15, 16, 19, 20] được định vị tốt hơn để xử lý việc tổng quát hóa kiến trúc chéo này.

Bảng 9 đưa ra kết quả theo mạch cho tất cả 30 lần. Hai nếp gấp bị thoái hóa (được đánh dấu †): RS232-T1800-90nm không có cổng trojan trong mạch đó và s38584-T300 chỉ có một. Cả hai đều không tạo ra ước tính độ chính xác/thu hồi ổn định và bị loại khỏi số liệu thống kê tổng hợp.

Giao thức loại bỏ một nhóm (LOFO) chặt chẽ hơn sẽ nhóm tất cả 30 mạch thành 5 nhóm nhóm (RS232, s15850, s35932, s38417, s38584) và lần lượt loại bỏ từng nhóm. Sử dụng các ngưỡng cố định nhất quán trên giấy (XGBoost = 0,940, RF = 0,820), cả hai phân loại đều sụp đổ: XGBoost vi trung bình $F1 = 0,033$ ($P = 0,025$, $R = 0,048$, $MCC = 0,026$). RF vi mô trung bình $F1 = 0,003$ ($P = 0,002$, $R = 0,003$, $MCC = -0,004$). LOFO xác nhận phát hiện LOCO ISCAS ở cấp độ gia đình và áp dụng cho cả hai

Table 9: Kết quả xác thực chéo LOCO trên mỗi mạch (XGBoost, ngưỡng 0,940, tất cả 30 lần). † Các nếp gấp thoái hóa (ít hơn 2 cổng trojan) bị loại khỏi tập hợp. F1 không xác định (-) khi mạch không có cổng trojan và 0,000 khi tồn tại trojan nhưng không phát hiện được.

Circuit	Tech	Trojans	TP / FP / FN	F1
<i>RS232 family (22 folds)</i>				
RS232-T1000	180nm	12	11 / 5 / 1	0.786
RS232-T1000	90nm	12	11 / 3 / 1	0.846
RS232-T1100	180nm	12	9 / 3 / 3	0.750
RS232-T1100	90nm	12	5 / 2 / 7	0.526
RS232-T1200	180nm	14	11 / 6 / 3	0.710
RS232-T1200	90nm	14	10 / 2 / 4	0.769
RS232-T1300	180nm	9	9 / 1 / 0	0.947
RS232-T1300	90nm	9	9 / 1 / 0	0.947
RS232-T1400	180nm	13	13 / 5 / 0	0.839
RS232-T1400	90nm	13	11 / 2 / 2	0.846
RS232-T1500	180nm	13	11 / 5 / 2	0.759
RS232-T1500	90nm	13	12 / 6 / 1	0.774
RS232-T1600	180nm	11	9 / 4 / 2	0.750
RS232-T1600	90nm	9	9 / 1 / 0	0.947
RS232-T1700	180nm	8	8 / 5 / 0	0.762
RS232-T1700	90nm	8	8 / 0 / 0	1.000
RS232-T1800	180nm	3	0 / 2 / 3	0.000
RS232-T1800†	90nm	0	0 / 1 / 0	—
RS232-T1900	180nm	16	6 / 2 / 10	0.500
RS232-T1900	90nm	16	5 / 1 / 11	0.455
RS232-T2000	180nm	11	7 / 1 / 4	0.737
RS232-T2000	90nm	11	7 / 1 / 4	0.737
<i>ISCAS benchmarks (8 folds)</i>				
s15850-T100	180nm	27	2 / 22 / 25	0.078
s35932-T100	180nm	14	2 / 0 / 12	0.250
s35932-T200	180nm	11	0 / 0 / 11	0.000
s35932-T300	180nm	34	0 / 0 / 34	0.000
s38417-T100	180nm	11	2 / 24 / 9	0.108
s38417-T200	180nm	14	0 / 20 / 14	0.000
s38584-T100	180nm	7	0 / 49 / 7	0.000
s38584-T300†	180nm	1	1 / 50 / 0	0.038

bộ phân loại: năm đặc điểm Hasegawa vô hướng không chuyển qua các danh sách mạng khác biệt về mặt kiến trúc. Các biểu diễn đồ thị cục bộ phong phú hơn [15, 16] cải thiện khả năng khái quát hóa xuyên mạch so với đường cơ sở năm tính năng, nhưng độ mạnh mẽ giữa các nhóm vẫn là một thách thức mở đối với điểm chuẩn Trust-Hub [16]. Bảng 10 cung cấp thông tin chi tiết theo từng gia đình.

Explanation stability across 90 nm and 180 nm process nodes.

Dòng RS232 là nhóm Trust-Hub duy nhất có các biến thể 90 nm và 180 nm được ghép nối trong điểm chuẩn này (11 thiết kế trojan với cả hai nút; s15850, s35932, s38417, s38584 chỉ có 180 nm). Bằng cách sử dụng phân chia ngẫu nhiên 60/20/20 chính, các giá trị SHAP cho bộ phát hiện XGBoost được so sánh giữa các cổng 90 nm ($n = 723, 6$ trojan) và các cổng 180 nm ($n = 10,669, 66$ trojan) của bộ thử nghiệm được tổ chức. Xếp hạng tính năng theo trung bình |SHAP| hoàn toàn ổn định trên các nút khi được tính toán trên tất cả các cổng kiểm tra:

Table 10: Kết quả xác thực chéo LOFO (bỏ một gia đình) cho mỗi gia đình. Ngưỡng XGBoost = 0,940. Ngưỡng RF=0,820. Số lượng cổng và trojan là phần thử nghiệm được tổ chức cho mỗi dòng. Tất cả năm nếp gấp không suy biến (≥ 3 cổng trojan cho mỗi lần thử nghiệm).

Family	Gates	Trojans	XGBoost			RF		
			P	R	F1	P	R	F1
RS232	6,483	239	0.060	0.046	0.052	0.000	0.000	0.000
s15850	2,595	27	0.080	0.074	0.077	0.000	0.000	0.000
s35932	20,484	59	0.009	0.034	0.015	0.000	0.000	0.000
s38417	12,015	25	0.011	0.040	0.018	0.000	0.000	0.000
s38584	15,382	8	0.006	0.125	0.011	0.008	0.125	0.016
Micro	56,959	358	0.025	0.048	0.033	0.002	0.003	0.003

$\rho_s = 1.000$ ($p < 0.001$, $n = 5$ tính năng). Đối với so sánh chỉ cổng trojan, thứ hạng toàn cầu 5 tính năng mang lại $\rho_s = 0.30$ ($p = 0.62$), nhưng chỉ có 6 cổng trojan từ mạch 90 nm trong lần thử nghiệm phân chia ngẫu nhiên, sự so sánh này không đủ mạnh về mặt thống kê và được báo cáo là một cảnh báo thay vì bằng chứng về sự không ổn định. Một Spearman lân cận gần nhất được ký cấp cổng- SHAP trên 6 cặp cổng trojan trùng khớp sẽ cho $\rho_s = 0.933$ (trung bình mỗi cổng, ± 0.075 ; phẳng $\rho_s = 0.879$), một lần nữa trên n nhỏ. Kết quả tiêu đề mà tính năng SHAP xếp hạng bài báo dựa vào (PO, FFO, LGFi, PI, FFi) là bất biến đối với sự khác biệt 90 nm/180 nm trên toàn bộ bộ thử nghiệm. Việc so sánh nút trên mỗi trojan yêu cầu nhiều mẫu trojan 90 nm hơn mức mà Trust-Hub cung cấp để đưa ra kết luận chắc chắn hơn.

Sự phân chia ngẫu nhiên 60/20/20 được báo cáo là kết quả đánh giá chính. Theo giao thức này, cả tập huấn luyện và tập kiểm tra đều chứa các cổng từ tất cả 30 mạch và mô hình được đánh giá dựa trên khả năng phân biệt các cổng trojan với các cổng lành tính có cùng phân bố tính năng cấp mạch. Giao thức này là một điều kiện thử nghiệm được kiểm soát để tách biệt những khác biệt của XAI giữa các phương pháp, chứ không phải là một tuyên bố về việc triển khai thực tế. Các kết quả LOCO và LOFO được báo cáo ở đây để mô tả ranh giới tổng quát của đường cơ sở năm tính năng.

Các hướng nghiên cứu trong tương lai bao gồm xác thực nhiều tập dữ liệu trên các họ mạch bổ sung, thư viện di động và các phương pháp chen trojan để kiểm tra khả năng khái quát hóa ngoài Trust-Hub; mở rộng không gian tính năng kết hợp mô phỏng chức năng, phân tích thời gian và chữ ký kênh bên, với kỹ thuật tính năng nhận biết miền (các thuộc tính tỷ lệ như LGFi/PO, các thuật ngữ tương tác như LGFi $\times$ FFo và các tính năng phân vị tương đối theo mạch) để tăng cường khả năng giải thích dựa trên thuộc tính; xử lý mất cân bằng nâng cao thông qua lấy mẫu tổng hợp và học tập nhạy cảm với chi phí; nghiên cứu đối tượng con người có kiểm soát với các kỹ sư bảo mật thực hành để định lượng khả năng hành động và sự tin cậy trên các phương pháp XAI; khả năng giải thích kết hợp kết hợp phân tích mạch nhận biết miền với phân bố bất khả tri theo mô hình; mở rộng khả năng phát hiện trojan kích hoạt tuần tự; và tổng hợp giải thích bằng ngôn ngữ tự nhiên bằng cách sử dụng các mô hình ngôn ngữ lớn [47, 48] để biến các mẫu thuộc tính, phân bố tính năng và mẫu trường hợp thành các báo cáo mà các kỹ sư có chuyên môn khác nhau có thể sử dụng được.

8 Conclusion

Công việc này so sánh năm cách tiếp cận có thể giải thích để phát hiện trojan phần cứng ở cấp độ cổng theo hai loại: phân tích thuộc tính nhận biết miền (M1) và các phương pháp bất khả tri mô hình, được chia thành lý luận dựa trên trường hợp dựa trên tiền lệ (M2) và phân bổ tính năng (LIME, SHAP, gradient; M3–M5). Hình 4 và Bảng 2 tóm tắt cách phân loại.

Trên 11.392 cổng kiểm tra được tổ chức từ Trust-Hub (157:1 lành tính với trojan), XGBoost ở ngưỡng val-tối ưu đạt độ chính xác 48,08% và thu hồi 69,44% (AUPRC = 0,637, $101\times$ so với không có kỹ năng), tăng độ chính xác gấp 4,25 lần so với được triển khai lại Đường cơ sở Hasegawa SVM (độ chính xác 11,33%, thu hồi 70,83%, $F1 = 0,195$). Ràng ngẫu nhiên đạt $F1 = 0,555$ với một nửa mật độ FP (2,37 so với 4,74 FP trên 1.000 cổng), xác nhận mức tăng không phụ thuộc vào bộ phân loại. Thử nghiệm của McNemar ($\chi^2(1) = 3578.23$, $p < 0.001$) và khoảng cách về độ chính xác 31,6 điểm phần trăm (99,33% so với 67,7%) xác nhận sự khác biệt giữa Phương pháp 1 và Phương pháp 2–5 là có ý nghĩa thống kê.

Về khả năng giải thích, phân tích thuộc tính tạo ra 31 mẫu dành riêng cho mạch (ví dụ: “LGFi cao gần PO biểu thị các mạch kích hoạt sự kiện hiếm gặp”); lý luận dựa trên trường hợp đạt được sự tương ứng 96,51% giữa các dự đoán và các lân cận đào tạo gần nhất với nguồn gốc danh sách mạng đầy đủ; LIME và SHAP đồng ý ở mức $\rho_s = 0.30$ mỗi cổng (KTC 95% [0.29, 0.31], $n = 11,392$) nhưng mang lại điểm quan trọng chung; phân bổ độ dốc phù hợp với thứ hạng SHAP ở tốc độ $7\times$ (0,16 mili giây so với 1,10 mili giây cho mỗi giải thích). Việc lựa chọn phương pháp xuất phát từ những sự cân bằng sau: phân tích thuộc tính trong đó các biện minh phù hợp với miền hỗ trợ xác thực kỹ sư, lý luận dựa trên trường hợp khi đủ tiền lệ và phân bổ tính năng như một công cụ khám phá vấn đề chuyên môn về miền để hành động.

9 Declarations

9.1 Funding

Các tác giả không nhận được hỗ trợ từ bất kỳ tổ chức nào cho tác phẩm được gửi.

9.2 Data Availability

Dữ liệu và mã được sử dụng trong công việc này có sẵn tại <https://github.com/paulwhitten/expl-phương-pháp-mã-phát-hiện-trojan>. Bộ dữ liệu điểm chuẩn Trust-Hub được cung cấp công khai tại <https://www.trust-hub.org/>.

References

- [1] Ribeiro, M.T., Singh, S., Guestrin, C.: ”tại sao tôi nên tin tưởng bạn?” giải thích các dự đoán của bất kỳ kỳ phân loại nào. Trong: Kỷ yếu của Hội nghị quốc tế ACM SIGKDD lần thứ 22 về Khám phá tri thức và khai thác dữ liệu, trang 1135–1144 (2016)

- [2] Lundberg, S.M., Lee, S.-I.: A unified approach to interpreting model predictions. *Advances in neural information processing systems* **30** (2017)
- [3] Simonyan, K., Vedaldi, A., Zisserman, A.: Deep inside convolutional networks: Visualising image classification models and saliency maps. *arXiv preprint arXiv:1312.6034* (2013)
- [4] Wolff, F., Papachristou, C., Bhunia, S., Chakraborty, R.S.: Towards trojan-free trusted ics: Problem analysis and detection scheme. In: *2008 Design, Automation and Test in Europe*, pp. 1362–1365 (2008). <https://doi.org/10.1109/DATE.2008.4484928>
- [5] Whitten, P., Wolff, F., Papachristou, C.: An ai architecture with the capability to classify and explain hardware trojans. In: *NAECON 2024 - IEEE National Aerospace and Electronics Conference*, pp. 349–354 (2024). <https://doi.org/10.1109/NAECON61878.2024.10670684> . <https://doi.org/10.1109/NAECON61878.2024.10670684>
- [6] Hasegawa, K., Oya, M., Yanagisawa, M., Togawa, N.: Hardware trojans classification for gate-level netlists based on machine learning. In: *2016 IEEE 22nd International Symposium on On-Line Testing and Robust System Design (IOLTS)*, pp. 203–206 (2016). <https://doi.org/10.1109/IOLTS.2016.7604700>
- [7] Hasegawa, K.: Hardware-trojan detection methods utilizing machine learning based on hardware-specific features. PhD thesis, Waseda University (2020)
- [8] Salmani, H., Tehranipoor, M., Sutikno, S., Wijitrisnanto, F.: Trust-Hub Trojan Benchmark for Hardware Trojan Detection Model Creation Using Machine Learning. <https://doi.org/10.21227/px6s-sm21> . <https://dx.doi.org/10.21227/px6s-sm21>
- [9] Negishi, R., Togawa, N.: Evaluation of ensemble learning models for hardware-trojan identification at gate-level netlists. In: *2024 IEEE International Conference on Consumer Electronics (ICCE)*, pp. 1–6 (2024). <https://doi.org/10.1109/ICCE59016.2024.10444240>
- [10] Salmani, H., Tehranipoor, M., Karri, R.: On design vulnerability analysis and trust benchmarks development. In: *2013 IEEE 31st International Conference on Computer Design (ICCD)*, pp. 471–474 (2013). <https://doi.org/10.1109/ICCD.2013.6657085>
- [11] Shakya, B., He, T., Salmani, H., Forte, D., Bhunia, S., Tehranipoor, M.: Benchmarking of hardware trojans and maliciously affected circuits. *Journal of Hardware and Systems Security* **1**, 85–102 (2017)
- [12] Slayback, S.M.: A computer scientist’s evaluation of publically available hardware trojan benchmarks. PhD thesis, Monterey, California: Naval Postgraduate School

(2015)

- [13] Rathor, V.S., Rastogi, A.: Ht-pred: An extensive methodology for dataset preparation and hardware trojan prediction using gate-level netlist. *Journal of Electronic Testing* **41**(4), 467–482 (2025)
- [14] King, G., Zeng, L.: Logistic regression in rare events data. *Political analysis* **9**(2), 137–163 (2001)
- [15] Mahfuz, T., Gaikwad, P., Suha, T., Bhunia, S., Chakraborty, P.: SALT:Y: Explainable Artificial Intelligence Guided Structural Analysis for Hardware Trojan Detection. In: 2025 IEEE 43rd VLSI Test Symposium (VTS), pp. 1–7 (2025). IEEE
- [16] Yasaei, R., Chen, L., Yu, S.-Y., Al Faruque, M.A.: Hardware trojan detection using graph neural networks. *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems* **44**(1), 25–38 (2022) <https://doi.org/10.1109/TCAD.2022.3178355>
- [17] Caruana, R., Kangaroo, H., Dionisio, J.D.N., Sinha, U.S., Johnson, D.B.: Case-based explanation of non-case-based learning methods. *Proceedings. AMIA Symposium*, 212–5 (1999)
- [18] Pan, Z., Mishra, P.: Hardware-assisted malware detection and localization using explainable machine learning. *IEEE Transactions on Computers* **71**(10), 2611–2622 (2022) <https://doi.org/10.1109/TC.2021.3120712>
- [19] Ma, P., Li, J., Liu, H., Shi, J., Zhang, S., Pan, W., Hao, Y.: Hardware Trojan detection methods for gate-level netlists based on graph neural networks. *IEEE Transactions on Computers* **74**(5), 1470–1481 (2025) <https://doi.org/10.1109/TC.2025.3533085>
- [20] Su, H., Hu, W., Zhang, X., Zhu, D., Wu, L.: Toward precise and explainable hardware Trojan localization at LUT level. *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems* **44**(7), 2817–2821 (2025) <https://doi.org/10.1109/TCAD.2025.3527377>
- [21] Gunning, D., Aha, D.W.: DARPA’s explainable artificial intelligence program. *AI Magazine* **40**(2), 44–58 (2019) <https://doi.org/10.1609/aimag.v40i2.2850>
- [22] Došilović, F.K., Brčić, M., Hlupić, N.: Explainable artificial intelligence: A survey. In: 2018 41st International Convention on Information and Communication Technology, Electronics and Microelectronics (MIPRO), pp. 0210–0215 (2018). <https://doi.org/10.23919/MIPRO.2018.8400040>
- [23] Fernandez, A., Herrera, F., Cordon, O., Jose del Jesus, M., Marcelloni, F.: Evolutionary fuzzy systems for explainable artificial intelligence: Why, when, what for,

- and where to? *IEEE Computational Intelligence Magazine* **14**(1), 69–81 (2019) <https://doi.org/10.1109/MCI.2018.2881645>
- [24] Hagras, H.: Toward human-understandable, explainable ai. *Computer* **51**(9), 28–36 (2018) <https://doi.org/10.1109/MC.2018.3620965>
 - [25] Howard, D., Edwards, M.A.: Explainable a.i.: The promise of genetic programming multi-run subtree encapsulation. In: 2018 International Conference on Machine Learning and Data Engineering (iCMLDE), pp. 158–159 (2018). <https://doi.org/10.1109/iCMLDE.2018.00037>
 - [26] Selvaraju, R.R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., Batra, D.: Grad-cam: Visual explanations from deep networks via gradient-based localization. In: Proceedings of the IEEE International Conference on Computer Vision, pp. 618–626 (2017)
 - [27] Doshi-Velez, F., Kim, B.: Towards a rigorous science of interpretable machine learning. *arXiv preprint arXiv:1702.08608* (2017)
 - [28] Guidotti, R., Monreale, A., Ruggieri, S., Turini, F., Giannotti, F., Pedreschi, D.: A survey of methods for explaining black box models. *ACM computing surveys (CSUR)* **51**(5), 1–42 (2018)
 - [29] Vilone, G., Longo, L.: Explainable artificial intelligence: a systematic review. *arXiv preprint arXiv:2006.00093* (2020)
 - [30] Arrieta, A.B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., García, S., Gil-López, S., Molina, D., Benjamins, R., *et al.*: Explainable artificial intelligence (xai): Concepts, taxonomies, opportunities and challenges toward responsible ai. *Information fusion* **58**, 82–115 (2020)
 - [31] Vaughan, J., Sudjianto, A., Brahimi, E., Chen, J., Nair, V.N.: Explainable neural networks based on additive index models. *arXiv preprint arXiv:1806.01933* (2018)
 - [32] Sweeney, J., Purdy, R., Blanton, R.D., Pileggi, L.: Circuitgraph: A python package for boolean circuits. *Journal of Open Source Software* **5**(56), 2646 (2020) <https://doi.org/10.21105/joss.02646>
 - [33] Shinan, E.: Lark: A modern parsing library for Python. *PyPI* (2024)
 - [34] Hagberg, A., Swart, P.J., Schult, D.A.: Exploring network structure, dynamics, and function using networkx. Technical report, Los Alamos National Laboratory (LANL), Los Alamos, NM (United States) (2008)
 - [35] Chen, T., Guestrin, C.: XGBoost: A scalable tree boosting system. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery

- and Data Mining. KDD '16, pp. 785–794. Association for Computing Machinery, New York, NY, USA (2016). <https://doi.org/10.1145/2939672.2939785> . <https://doi.org/10.1145/2939672.2939785>
- [36] Whitten, P., Wolff, F., Papachristou, C.: An ai architecture with the capability to explain recognition results. In: 2024 IEEE 3rd International Conference on Computing and Machine Intelligence (ICMI), pp. 1–6 (2024). <https://doi.org/10.1109/ICMI60790.2024.10586116> . <https://doi.org/10.1109/ICMI60790.2024.10586116>
 - [37] Whitten, P., Wolff, F., Papachristou, C.: Case-Explainer: General-Purpose Case-Based Explainability, (2025). <https://github.com/paulwhitten/case-explainer>
 - [38] Whitten, P.C.: Explainable ai architectures: Methods, applications, examples, and results. PhD thesis, Case Western Reserve University (2025). http://rave.ohiolink.edu/etdc/view?acc_num=case1743462769378071
 - [39] Neyman, J., Pearson, E.S.: Ix. on the problem of the most efficient tests of statistical hypotheses. Philosophical Transactions of the Royal Society of London, Series A: Containing Papers of a Mathematical or Physical Character **231**(694-706), 289–337 (1933) <https://doi.org/10.1098/rsta.1933.0009> <https://royalsocietypublishing.org/rsta/article-pdf/231/694-706/289/240090/rsta.1933.0009.pdf>
 - [40] Green, D.M., Swets, J.A.: Signal Detection Theory and Psychophysics. Wiley, New York (1966)
 - [41] Fawcett, T.: An introduction to roc analysis. Pattern recognition letters **27**(8), 861–874 (2006)
 - [42] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., Duchesnay, E.: Scikit-learn: Machine learning in Python. Journal of Machine Learning Research **12**, 2825–2830 (2011)
 - [43] Gansner, E.R., North, S.C.: An open graph visualization system and its applications to software engineering. Software: Practice and Experience **30**(11), 1203–1233 (2000)
 - [44] Japkowicz, N., Shah, M.: Evaluating learning algorithms: A classification perspective. Evaluating Learning Algorithms. A Classification Perspective (2011) <https://doi.org/10.1017/CBO9780511921803>
 - [45] Dietterich, T.G.: Approximate statistical tests for comparing supervised classification learning algorithms. Neural computation **10**(7), 1895–1923 (1998)
 - [46] Mohseni, S., Zarei, N., Ragan, E.D.: A multidisciplinary survey and framework for design and evaluation of explainable ai systems. ACM Transactions on Interactive

Intelligent Systems (TiiS) **11**(3–4), 1–45 (2021)

[47] Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J.D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., *et al.*: Mô hình ngôn ngữ là những người học ít lần. Những tiến bộ trong hệ thống xử lý thông tin thần kinh **33**, 1877–1901 (2020)

[48] Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bash-lykov, N., Batra, S., Bhargava, P., Bhosale, S., *et al.*: Llama 2: Nền tảng mở và các mô hình trò chuyện tinh chỉnh. bản in trước arXiv arXiv:2307.09288 (2023)